

## 1 ENTENDIMIENTO DEL NEGOCIO

---

Los páramos son ecosistemas de alta montaña extremadamente importantes para la regulación del agua y la biodiversidad. En estos ecosistemas, los frailejones *Espeletia spp.* juegan un papel importante como especies clave en la captura y retención de agua. Estas plantas pueden capturar humedad del aire y liberarla lentamente en el suelo, formando cuencas de agua que son fuentes de agua para millones de personas. Los frailejones son especies endémicas de los páramos de Venezuela, Colombia y Ecuador que se extienden hasta Perú. Su crecimiento es lento, sólo aproximadamente 1 cm por año, haciéndose más vulnerable a los cambios ambientales, la intervención humana y el efecto del cambio climático.

En Colombia, en los páramos de Chingaza y Cruz Verde se localizan fuentes hídricas esenciales. Chingaza abastece de agua a más del 70% de Bogotá y municipios aledaños. Sin embargo, amenazas como la expansión ganadera, incendios, actividades mineras y cambio climático ponen en riesgo la población de frailejones. En enero de 2024 se produjo un incendio en el sector del cruce de San Jacinto, el páramo de Chingaza donde se vieron afectadas cerca de 30 hectáreas y miles de frailejones resultaron quemados.

Desde abril de 2024, y debido a las sequías prolongadas producto del fenómeno del Niño, los niveles de agua del embalse de Chingaza bajaron hasta la cifra de 15%, el nivel más bajo registrado desde su origen, en consecuencia y debido a la gravedad de la situación se han implementado medidas de racionamiento de agua en la ciudad de Bogotá y municipios aledaños. Entendiendo que los frailejones son parte fundamental en el ecosistema del páramo y que son cruciales para la captura y retención del agua. La importancia de su conservación, preservación y monitoreo son esenciales.

Si bien la presencia de los frailejones es abundante en el páramo de Chingaza no se dispone de una estimación precisa de la población de esta especie en esta área y de igual forma se desconoce cómo su población puede llegar a estar afectada por variables como la altitud, la acidez del suelo y/o condiciones climáticas. En este sentido el propósito de este proyecto es lograr realizar una detección automática de la especie de frailejones a partir de imágenes aéreas capturadas por drones y consecuentemente estimar una densidad población de los frailejones para esta misma área.

## 2 OBJETIVOS DE MINERÍA DE DATOS

---

Como objetivo general del proyecto se plantea el desarrollo de un sistema que logre identificar de manera automática la especie de frailejones usando una combinación de redes neuronales sencillas, multicapa, convolucional y convolucional +VGG16, para analizar imágenes aéreas capturadas por drones y además calcular una estimación de la densidad poblacional de frailejones en el páramo de Chingaza, con estos resultados se busca mejorar las estrategias de conservación y monitoreo de este ecosistema crítico.

Como objetivos de minería de datos para este proyecto se plantean:

- Preprocesar y analizar las imágenes aéreas capturadas por drones para detectar frailejones mediante técnicas de visión por computadora.
- Evaluar y comparar el desempeño de diferentes arquitecturas de redes neuronales en la identificación de frailejones, incluyendo:
  - Red Neuronal Sencilla (Precisión esperada: 0.88).
  - Red Neuronal Multicapa (Precisión esperada: 0.95).
  - Red Neuronal Convolucional (CNN) (Precisión esperada: 0.95).
  - Red Neuronal Convolucional con transferencia de aprendizaje usando VGG16 (Precisión esperada: 0.99).
- Entrenar y optimizar los modelos de redes neuronales, ajustando los hiperparámetros y usando técnicas de aumento de datos (data augmentation) para mejorar la precisión del reconocimiento.
- Validar los modelos desarrollados utilizando métricas de desempeño como exactitud, precisión, recall y F1-score.
- Calcular la densidad poblacional de frailejones en diferentes zonas del páramo, utilizando los resultados del modelo de detección.

### 3 ENTENDIMIENTO DE LOS DATOS

#### 3.1 DESCRIPCIÓN DE LOS DATOS

Para este proyecto se trabajará con dos conjuntos de datos principales. El primero es una imagen de prueba (IMG\_3451.JPG), que consiste en una imagen aérea del páramo para análisis cualitativo. Esta imagen fue tomada con una cámara Canon PowerShot S100, tiene dimensiones de 4000x3000 píxeles, utiliza espacio de color RGB y fue capturada en las coordenadas 4° 34' 26,79" N, 74° 1' 22,859" O. El segundo conjunto de datos es el archivo data\_F, que contiene imágenes clasificadas y etiquetadas en dos categorías: frailejones y no-frailejones. Este conjunto incluye múltiples ejemplos de cada categoría, capturados bajo diversas condiciones de iluminación y ángulos, lo que permite una representación variada de las características distintivas de los frailejones.

#### 3.2 EXPLORACIÓN DE LOS DATOS




Ilustración 1. imágenes Original y Escala de Grises

Ilustración 2. Histograma Escala de Grises

Para la imagen de prueba IMG\_3451.JPG (ilustración 1), el análisis exploratorio reveló características significativas. En términos de color, se observó una predominancia de tonos verdeazulados, con una distribución bimodal clara en el histograma (ilustración 2) de escala de grises, mostrando picos distintivos en los rangos 120-130 (tonos medios-oscuros) y 200-210 (tonos más claros). Las características de textura fueron igualmente reveladoras, con un contraste de 697.0758 que indica una alta variación local, una homogeneidad de 0.0608 que sugiere una textura irregular, y una energía de 0.0090 que confirma la complejidad de la textura en las imágenes.




Ilustración 3. Comparación Visual de Ejemplos de Imágenes Satelitales: Frailejón vs. No Frailejón

El análisis exploratorio del dataset data\_F revela aspectos importantes sobre las imágenes satelitales analizadas. El conjunto de datos está estructurado en dos categorías: Frailejón y No Frailejón, con 21 y 29 muestras respectivamente, cada una con dimensiones de 100x100 píxeles y 3 canales de color. La distribución de intensidad de los píxeles muestra diferencias significativas: las imágenes de Frailejón tienen valores que van desde 11 hasta 255 (sin negros puros) con una media de 161.96, mientras que las de No Frailejón abarcan todo el espectro posible (0-255) con una media más baja de 137.92.

La media más alta en Frailejón (161.96) indica que estas imágenes tienden a ser más brillantes, mientras que la media más baja en No Frailejón (137.92) confirma que son generalmente más oscuras. Las desviaciones estándar (56.68 para Frailejón y 51.27 para No Frailejón) son similares entre sí y relativamente altas, lo que indica una variabilidad comparable en los niveles de brillo y un buen contraste dentro de las imágenes, facilitando la identificación de patrones

y estructuras características de cada clase. Estas diferencias estadísticas se manifiestan visualmente en la ilustración 3 donde se ven las imágenes de ejemplo, donde los Frailejones presentan una estructura más brillante y distintiva, en contraste con las imágenes de No Frailejón que muestran áreas más oscuras y una composición más uniforme.

### 3.3 REVISIÓN DE LA CALIDAD DE LOS DATOS

Para la imagen de prueba (IMG\_3451.JPG), se evaluaron aspectos de calidad. Las condiciones de iluminación son generalmente uniformes, lo que beneficia el análisis posterior. Sin embargo, se identificó presencia de ruido en áreas de alta complejidad textural, variaciones locales en el contraste, y la existencia de bordes poco definidos en ciertas regiones de la imagen. Estos factores podrían afectar la identificación de frailejones.

Para el conjunto de datos data\_F, el análisis de calidad reveló características importantes para el análisis. La distribución de clases, aunque no perfectamente balanceada (21 frailejones vs 29 no-frailejones), mantiene una proporción razonable. Los rangos de intensidad de píxeles muestran patrones distintivos para cada clase, con los frailejones presentando valores más brillantes (11-255) y los no-frailejones abarcando el espectro completo (0-255). La consistencia en las desviaciones estándar entre clases ( $\approx 51$ -56) indica una variabilidad comparable en la calidad de las imágenes de ambas categorías.

## 4 PREPARACIÓN DE LOS DATOS

---

### 4.1 LIMPIEZA DE LOS DATOS

Para la imagen de prueba, se realizó una conversión inicial del formato de imagen a array NumPy y su transformación a escala de grises mediante cv2.COLOR\_RGB2GRAY, preparándola para el procesamiento posterior. En el caso del conjunto data\_F, se implementó un proceso de normalización dividiendo los valores de píxeles entre 255, llevándolos al rango [0,1], dejando así una escala uniforme para todos los datos y optimizando su procesamiento posterior.

### 4.2 CONSTRUCCIÓN DE LOS DATOS

Para la imagen de prueba se realizó una aplicación de umbral adaptativo y una limpieza mediante operaciones morfológicas para reducir ruido, y detección de contornos con filtrado por área (entre 20 y 5000 unidades) para identificar regiones de interés. Para el conjunto data\_F, se implementó una estrategia de aumento de datos que generó 5 variaciones de cada imagen original (70x70 píxeles), expandiendo el conjunto inicial de 50 imágenes a 250 ejemplos. Estos datos fueron reestructurados mediante el aplanamiento de las imágenes a vectores de 14700 dimensiones (70x70x3) y organizados en matrices de entrenamiento (14700, 175) y validación (14700, 75), con sus correspondientes vectores de etiquetas, utilizando una división estratificada 70/30. La división se realizó usando train\_test\_split con un parámetro test\_size de 0.3 y random\_state de 100 para la reproducibilidad.

### 4.3 DESCRIPCIÓN DEL NUEVO CONJUNTO DE DATOS.

El conjunto de datos final presenta una estructura optimizada con 250 ejemplos totales divididos en 175 para entrenamiento y 75 para validación, donde cada ejemplo es un vector normalizado de 14700 dimensiones que representa una imagen de 70x70 píxeles con 3 canales de color. Las etiquetas binarias permiten la clasificación supervisada de frailejones. Por su parte, la imagen de prueba fue transformada en un formato que permite la detección automatizada de frailejones mediante técnicas avanzadas de procesamiento de imágenes, incluyendo umbralización adaptativa y análisis de contornos, resultando en la identificación de regiones que contienen estas plantas.

## 5 METODOLOGÍA - MODELAMIENTO

---

### 5.1 SELECCIÓN DE TÉCNICAS DE MODELADO.

Como premisa para abordar la etapa de modelamiento de este proceso se tiene el uso de una combinación de redes neuronales esperando ciertas métricas de precisión. Siendo así se entrenan los siguientes modelos esperando el correspondiente nivel de Accuracy que se propone en la siguiente tabla.

MODELO	ACCURACY/AUC ESPERADO
Red Neuronal Sencilla	0.88
Red Neuronal Multi-Capa	0.95
Red Neuronal Convolutacional	0.95
Red Neuronal Convolutacional + VGG16	0.99

Tabla 1. Técnicas y Modelos para Aplicar

## 5.2 CONSTRUCCIÓN DEL MODELO IDENTIFICACIÓN AUTOMÁTICA DE FRAILEJONES

### 5.2.1 Modelo 1-Red Neuronal Sencilla

En la tabla 2 Arquitectura y Entrenamiento de la Red Neuronal sencilla se da el detalle y los resultados para cada uno de los intentos que se realizaron en la construcción de esta red.

ID	CAPA DE ENTRADA			CAPA DROPOUT	HIPERPARAMETROS	CONSIDERACIONES ADICIONALES	TRAIN ACC	TEST ACC	AUC
	CANTIDAD NEURONAS	Normalización por Lotes	Función de Activación						
1	Mejor Valor entre 32 y 512, incrementos de 32 con Keras Tuner	N/A	Relu	Mejor Valor 0.0 y 0.5 en incrementos de 0.1 con Keras Tuner	Búsqueda y Optimización de Hiperparametros RandomSearch con Keras Tuner	N/A	0.8685	0.8133	0.8691
2	Mejor Valor entre 32 y 512, incrementos de 32 con Keras Tuner	N/A	Mejor Función entre ReLu, Tanh y ELU con Keras Tuner	Mejor Valor 0.0 y 0.5 en incrementos de 0.1 con Keras Tuner	Optimización de Hiperparametros BayesianOptimization con Keras Tuner	N/A	0.8399	0.8666	0.9077
3	Mejor Valor entre 64 y 1024, paso de 64 con Keras Tuner	BatchNormalization que estabiliza el entrenamiento y acelera la convergencia	$Mish(x) = x * \tanh(\text{softplus}(x))$	Mejor Valor 0.0 y 0.6 en incrementos de .1 con Keras Tuner	Optimización de Hiperparametros BayesianOptimization con Keras Tuner	Preprocesamiento de datos con StandarScaler, inclusión de Early Stopping para prevenir sobreajuste, mayor número de épocas y pruebas.	1.000	0.9066	0.9073

Tabla 2. Entrenamiento y Pruebas Red Neuronal Sencilla

En la tercera versión de esta red neuronal se logra superar el Accuracy esperado del 0.88 con un valor 0.9073. A partir del mejor modelo se realizan las predicciones de la imagen del páramo para identificar los frailejones. Los resultados se muestran en la ilustración 4.




Ilustración 4. Predicciones del modelo red neuronal sencilla




Ilustración 5. Predicciones del modelo red neuronal multicapa

### 5.2.2 Modelo 2-Red Neuronal Multicapa

Se empezó con la misma estructura que se había encontrado en la red neuronal sencilla ya que el modelo presentaba buena calificación en sus métricas. A continuación, se presenta cada intento con las estrategias implementadas y las métricas del modelo.

Primer intento	Segundo intento	Tercer intento	Cuarto intento	Quinto intento	Sexto intento
<ul style="list-style-type: none"> <li>- Función de Activación Mish</li> <li>- Búsqueda de hiperparámetros como npumero de capas, número de neuronas con Bayesian Optimization</li> <li>-Batch Normalization</li> <li>- Dropout</li> <li>- Optimizador Adam</li> <li>- Función de pérdida binary crossentropy</li> <li>- Métrica Accuracy</li> </ul>	<ul style="list-style-type: none"> <li>- Se expande los límites de búsqueda de hiperparámetros</li> <li>- Patience del early stopping se duplicó</li> <li>- El resto es semejante al intento anterior.</li> </ul>	<ul style="list-style-type: none"> <li>- Regularización L1 y L2</li> <li>- Aumento del paso en la búsqueda de hiperparámetros</li> <li>- Aumentar valores mínimos de dropout</li> <li>- Aumenta rango de búsqueda de tasa de aprendizaje</li> <li>- Disminución del trial</li> <li>- El resto es semejante al intento anterior.</li> </ul>	<ul style="list-style-type: none"> <li>- Eliminación de la regularización</li> <li>- Optimizador Optuna</li> <li>- El resto es semejante al intento anterior.</li> </ul>	<ul style="list-style-type: none"> <li>- Se vuelve al optimizador Bayesian Optimizarion</li> <li>- El resto es semejante al intento anterior.</li> </ul>	<ul style="list-style-type: none"> <li>- Validación cruzada por KFold</li> <li>- Reducción de trials</li> <li>- Evaluación del rendimiento del modelo por promedio de las métricas de cada submodelo de los folds</li> <li>- El resto es semejante al intento anterior.</li> </ul>

- Standard Scaler					
Train Acc: 0.994 Test Acc:0.907 AUC:0.908	Train Acc: 0.988 Test Acc:0.920 AUC:0.918	Train Acc: 0.991 Test Acc:0.906 AUC:0.905	Train Acc: 1.0 Test Acc:0.853 AUC:0.902	Train Acc: 0.988 Test Acc:0.920 AUC:0.919	Train Acc: 0.992 Test Acc:0.948 AUC:0.972

Tabla 3. Entrenamiento y Métricas Red Neuronal Multicapa

A partir del mejor modelo se realizan las predicciones de la imagen del páramo para identificar los frailejones. Los resultados se muestran en la ilustración 5.

Se observa que la red neuronal multicapa no tiene casi falsos positivos, pero algunos frailejones no son identificados por el modelo. Adicionalmente, no confunde las personas con frailejones lo cual representa un correcto aprendizaje de la red. Adicionalmente, se observaba que en otros modelos había el problema de que los árboles que están en el modelo de la imagen a veces eran detectados y confundidos con frailejones, lo cual no sucede en este modelo y representa un correcto aprendizaje de las características de los frailejones. Por último, las zonas donde no detecta adecuadamente son donde hay sobre iluminación en comparación del resto de la foto, influyendo en la predicción. A pesar de ello, el modelo se considera que tiene un correcto desempeño por identificar la mayoría de los frailejones.

### 5.2.3 Modelo 3-Red Neuronal Convolucional

Se empezó con una estructura sencilla aleatoria decidida por el equipo. A continuación, se presenta cada intento con las estrategias implementadas y las métricas del modelo.

Primer intento	Segundo intento	Tercer intento	Cuarto intento	Quinto intento	Sexto intento
- Primera capa convolucional 3 filtros 3x3 con Relu - Segunda capa convolucional 64 filtros - MaxPooling cada capa Intermedia - Una capa densa de 128 neuronas con Relu - Optimizador Adam - Función de pérdida binary crossentropy - Métrica Accuracy	- Optimizador Optuna - Búsqueda de hiperparámetros de cantidad de filtros de capas convolucionales, número de neuronas. - Early Stopping - El resto es semejante al intento anterior.	- Guardar el mejor modelo entrenado y trabajar sobre el - El resto es semejante al intento anterior.	- Permitir que Optuna optimice no solo hiperparámetros sino la estructura de la red - Dropout - Aumento de paciencia del early stopping de 5 a 20 épocas. - Aumento número de trials - El resto es semejante al intento anterior.	- Standard Scaler - El resto es semejante al intento anterior.	- Validación cruzada por KFold - Optimización de hiperparámetros en cada fold - Evaluación del rendimiento del modelo por promedio de las métricas de cada submodelo de los folds - El resto es semejante al intento anterior.
Train Acc: 0.908 Test Acc:0.879 AUC:0.943	Train Acc: 0.906 Test Acc:0.426 AUC:0.666	Train Acc: 0.925 Test Acc:0.906 AUC:0.021	Train Acc: 0.885 Test Acc:0.906 AUC:0.917	Train Acc: 0.971 Test Acc:0.954 AUC:0.962	Train Acc: 0.992 Test Acc:0.948 AUC:0.961

Tabla 4. Entrenamiento y Métricas Red Neuronal Convolucional

A partir del mejor modelo se realizan las predicciones de la imagen del páramo para identificar los frailejones. Los resultados se muestran en la ilustración 6.




Ilustración 6. Predicciones del modelo red neuronal convolucional




Ilustración 7. Predicciones del modelo red VGG16

En la imagen se observa que presenta varios falsos positivos en las zonas donde hay árboles y arbustos, lo cual demuestra que el modelo confunde las características de esta vegetación con los frailejones. Sin embargo, el modelo es muy bueno prediciendo en las zonas con sobre iluminación, pues allí a diferencia de otros modelos identifico a todos los frailejones con casi ningún falso positivo. Por último, el modelo es capaz de diferenciar las personas de los frailejones, siendo señal de un aprendizaje de características como color y forma de los frailejones.

### 5.2.4 Modelo 4-Red Neuronal VGG16

Se implementó una red neuronal VGG16 seguido de una capa densa de 256 neuronas y función de activación Relu. A continuación, se presenta cada intento con las estrategias implementadas y las métricas del modelo.



Primer intento	Segundo intento
<ul style="list-style-type: none"> <li>- Optimizador de hiperparámetros Optuna</li> <li>- CNN pre entrenada VGG16</li> <li>- Stándard Scaler</li> <li>- Dropout</li> <li>- Early Stopping</li> <li>- Función de pérdida binary crossentropy</li> <li>- Métrica Accuracy</li> </ul>	<ul style="list-style-type: none"> <li>- Implementación aumento de datos, aplicando rotaciones, desplazamientos, zoom y volteos horizontales, usando ImageDataGenerator</li> <li>- El resto es semejante al intento anterior.</li> </ul>
<b>Train Acc:</b> 1.0 <b>Test Acc:</b> 0.973 <b>AUC:</b> 0.991	<b>Train Acc:</b> 1.0 <b>Test Acc:</b> 0.973 <b>AUC:</b> 0.991

Tabla 5. Entrenamiento y Métricas Red Neuronal VGG16

Se observa en la ilustración 7 que la red neuronal VGG16 no tiene casi falsos positivos (únicamente 3), pero algunos frailejones no son identificados por el modelo, mayoritariamente los ubicados en las zonas con mayor iluminación. Adicionalmente, no confunde las personas con frailejones lo cual representa un correcto aprendizaje de la red. Se identifica que en otros modelos había el problema de que los árboles que están en el modelo de la imagen a veces eran detectados y confundidos con frailejones, lo cual no sucede en este modelo y representa un correcto aprendizaje de las características de los frailejones. Por último, las zonas donde no detecta adecuadamente son donde hay sobre iluminación en el suelo en comparación del resto de la foto, influyendo en la predicción. A pesar de ello, el modelo se considera que tiene un correcto desempeño por identificar la mayoría de los frailejones.

### ¿Y Por qué se aplicaron esas estrategias en los modelos 1 al 4?

- **Función de Activación Mish:** Su objetivo es mejorar el flujo del gradiente y la capacidad de generalización. La función de activación Mish agrega suavidad y continuidad. La suavidad ayuda a que el algoritmo de gradiente descendiente se comporte de manera más estable y con respecto a la continuidad permite que la información fluya a través de la red con mayor facilidad y ayuda a mejorar la convergencia y la generalización.
- **Batch Normalization:** Ayuda a estabilizar el entrenamiento y acelerar la convergencia al normalizar las activaciones de las capas.
- **Búsqueda de Hiperparámetros con Bayesian Optimization:** Esta es una técnica para encontrar la combinación óptima de hiperparámetros (número de capas, neuronas, tasa de aprendizaje). Es más eficiente que la búsqueda de cuadrícula o aleatoria.
- **Dropout:** Una técnica de regularización que previene el sobreajuste al desactivar aleatoriamente algunas neuronas durante el entrenamiento.
- **Optimizador Adam:** Un optimizador eficiente y adaptable que funciona bien en una amplia variedad de problemas.
- **Función de Pérdida Binary Crossentropy:** Indica que estás trabajando en un problema de clasificación binaria.
- **Standard Scaler:** Es una técnica de preprocesamiento de los datos, que normaliza las variables, haciendo que estas tengan una media de cero y una desviación estándar de 1.
- **Expansión de los límites de búsqueda de hiperparámetros:** Busca obtener un espacio de búsqueda más amplio para que la optimización bayesiana tenga más opciones.
- **Early Stopping:** Esta función permite detener el entrenamiento cuando la función de pérdida desmejora. Con esta técnica se previene el sobreajuste.
- **Aumento de la "patience" del early stopping:** El early stopping es una técnica que detiene el entrenamiento cuando no ve mejoras en un número determinado de épocas, al duplicar la paciencia, le da más tiempo al modelo para que encuentre una mejora y no se estanque en un óptimo local.
- **Regularización L1 y L2:** Técnicas para prevenir el sobreajuste al penalizar los pesos grandes. Aunque para nuestro caso no fue eficiente ya que aplicar Dropout ya generaba regularización y L1 y L2 estaban limitando a la red neuronal de aprender detalles de la imagen a profundidad.
- **Optimizador Optuna:** Optuna es una librería de optimización de hiperparámetros, que al igual que Bayesian Optimization, busca la mejor combinación de hiperparámetros. Tiende a tener mayor eficiencia su búsqueda.
- **Validación cruzada por K-folds:** Una técnica robusta para evaluar el rendimiento del modelo en diferentes subconjuntos de datos. Esto permitió que un modelo se especialice más en una data o características y al unir los modelos se pueda tener un modelo general más robusto, captando más profundidad en las características. La evaluación del rendimiento por promedio de métricas proporciona una estimación más confiable del rendimiento general.

- **Capas Convolucionales:** La transición a una CNN permite el procesamiento efectivo de datos de imagen. Tener Capas Convolucionales (3x3 filtros, ReLU) permiten que la red aprenda características espaciales jerárquicas de las imágenes. Los filtros 3x3 son comunes para capturar patrones locales. ReLU ayuda a mitigar el desvanecimiento del gradiente. Las Capas Densas Post Convolutional: Realiza la clasificación final basada en las características extraídas por las capas convolucionales.
- **MaxPooling:** Reduce la dimensionalidad de las características, lo que disminuye la carga computacional y ayuda a prevenir el sobreajuste.
- **CNN Pre-entrenada VGG16:** VGG16 es una arquitectura de red neuronal convolucional (CNN) que fue entrenada en un gran conjunto de datos de imágenes (ImageNet). Tiene beneficios como
  - Transferencia de aprendizaje: Permite aprovechar las características aprendidas por la red en ImageNet para su propio conjunto de datos, incluso si este es pequeño.
  - Aceleración del entrenamiento: Reduce el tiempo de entrenamiento, ya que no es necesario entrenar la red desde cero.
  - Mejora del rendimiento: Puede mejorar la precisión del modelo, especialmente cuando se trabaja con conjuntos de datos limitados.
  - Extracción de características: Permite utilizar las capas convolucionales de VGG16 como un extractor de características, y luego conectar esas características a capas densas, para realizar la clasificación propia del problema que se esté abordando.
- **Aumento de Datos (ImageDataGenerator):** El aumento de datos es una técnica que crea nuevas muestras de entrenamiento a partir de las existentes, aplicando transformaciones como rotaciones, desplazamientos, zoom y volteos. Esto ayuda a reducir el sobreajuste, mejora la generalización, aumenta el tamaño del conjunto de datos a partir de creación de datos realistas.

### 5.2.5 Modelo 5-Red Neuronal Propuesta

ResNet-50 es una **red neuronal convolucional profunda** desarrollada por Microsoft, ampliamente utilizada en visión por computadora. Su arquitectura se basa en **bloques residuales**, que permiten entrenar redes profundas sin que el gradiente se disipe o explote. Gracias a estos bloques, ResNet-50 puede capturar patrones complejos en imágenes mientras mantiene un entrenamiento estable y eficiente.

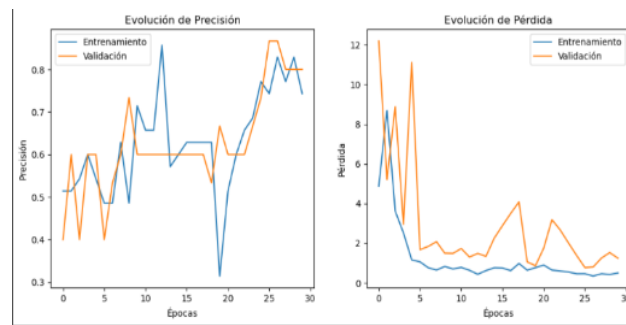


Ilustración 8. Gráfica de precisión y pérdida

En este caso, se utilizó **ResNet-50 preentrenado con pesos de ImageNet** para aprovechar el conocimiento aprendido en millones de imágenes. Se congelaron la mayoría de las capas y solo se entrenaron las **últimas 10 capas**, lo que permitió ajustar el modelo a la tarea específica sin perder las características generales aprendidas. Tras evaluar **20 configuraciones de hiperparámetros**, el mejor modelo logró una **precisión del 93.33%** en el conjunto de prueba. Los parámetros óptimos fueron:

- **Dropout Rate:** 0.221 → Regularización moderada para evitar sobreajuste.
- **Learning Rate:** 0.00083 → Ajuste fino de los pesos sin cambios bruscos.
- **Batch Size:** 32 → Equilibrio entre velocidad y estabilidad en el entrenamiento.

Estos resultados se reflejan en la **gráfica de precisión y pérdida (Ilustración 8):**

- En la **gráfica de precisión**, se observa que el modelo alcanza una **alta precisión** con cierta variabilidad inicial, pero estabilizándose en las últimas épocas.

- En la **gráfica de pérdida**, la curva disminuye progresivamente, lo que indica que el modelo aprende correctamente, aunque con algunas fluctuaciones en validación, que podrían sugerir ajustes adicionales para mejorar la estabilidad.

El uso de **ResNet-50 con fine-tuning parcial** permitió alcanzar una precisión **superior al 93%**, lo que demuestra la efectividad del **transfer learning** en esta tarea. Sin embargo, el comportamiento de la pérdida en validación sugiere que podrían aplicarse técnicas adicionales, como **early stopping** o **más regularización**, para mejorar la estabilidad y evitar posibles signos de sobreajuste.

## 6 CONSTRUCCIÓN DEL MODELO DENSIDAD POBLACIONAL

### 6.1 Modelo 1-Densidad Poblacional

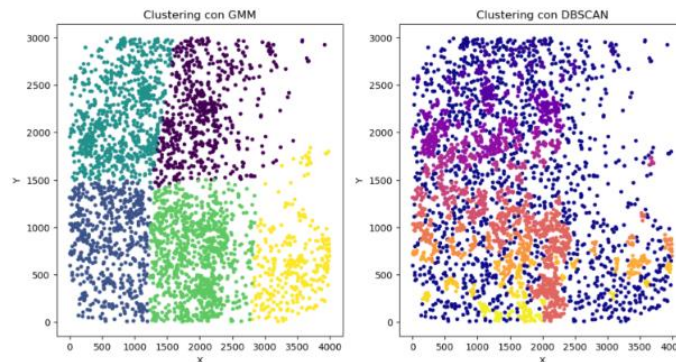


Ilustración 9. Clustering con GMM y Clustering con DBSCAN

En la ilustración 9 es posible encontrar que ambos modelos, muestran 5 clústeres. El **modelo GMM** asume que los datos provienen de distribuciones gaussianas, permitiendo una segmentación estructurada. En la imagen izquierda, los clústeres están bien definidos con fronteras claras, lo que indica una clasificación ordenada. Esto sugiere que los datos tienen una distribución homogénea y se pueden dividir en regiones diferenciadas.

En cambio, **DBSCAN** agrupa puntos en función de su densidad, sin imponer una forma específica a los clústeres. En la imagen derecha, se observa una distribución más dispersa y con puntos marcados como ruido. Este resultado indica que los datos no siguen una estructura rígida y pueden tener zonas de mayor y menor densidad, permitiendo detectar patrones más naturales.

### 6.2 Modelo 2-Densidad Poblacional




Ilustración 10. Detección de Frailejones

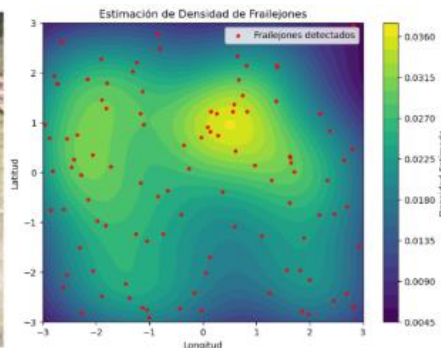


Ilustración 11. Detección de Frailejones

#### 6.2.1 Conversión a escala de grises y umbral adaptativo

Convertir una imagen a escala de grises facilita la segmentación y detección de los elementos de interés. Aplicando un **umbral adaptativo**, podemos resaltar regiones específicas, como los frailejones detectados en la ilustración 10, donde



aparecen marcados en rojo. En esta los frailejones detectados aparecen resaltados en rojo sobre un fondo natural. Como se observa en el desempeño del análisis, no es el mejor posible, ya que el uso de la escala de grises toma en cuenta los grises, todo aquello que sea un color más oscuro lo toma como un frailejón.

### 6.2.2 Kernel Density Estimation (KDE)

Es un método de estimación de densidad no paramétrico que permite visualizar la distribución espacial de puntos en una región. KDE crea un mapa de calor suavizado a partir de las ubicaciones de los frailejones, como se observa en la ilustración 11, donde las zonas amarillas representan áreas de mayor densidad. Ahora bien, la **estimación de densidad KDE** muestra las áreas donde los frailejones están más concentrados. Las zonas amarillas indican mayor densidad, mientras que las zonas azul oscuro representan áreas con pocos frailejones. La suma de la cantidad de frailejones es de 105. Este modelo muestra un mejor desempeño, ya que usa la información sobre la posición y no una escala que depende de una escala de colores.

## 7 SOLUCIÓN PROPUESTA - EVALUACIÓN

---

### 7.1 EVALUACIÓN MODELOS PREDICCIÓN DE FRAILEJONES

Los 5 modelos cumplieron con las métricas base, demostrando un buen desempeño en Accuracy y AUC. A partir de ello y los análisis cualitativos, se observa que cada modelo presento que era mejor identificando características específicas; el modelo convolucional fue bueno para identificar frailejones en zonas con alta iluminación; la red sencilla y multicapa fue buena para identificar frailejones en zonas con iluminación intermedia; y la red VGG16 se destacó por diferenciar los frailejones de otros tipos de vegetación, aparte de ser la que mejor identificación tuvo. La cantidad de falsos positivos fueron bajos además de que fueron muy pocos los frailejones que no identifiqué. Es por lo que, debido a que tuvo el mejor desempeño en Accuracy (0,97), AUC (0,99) y cualitativo (identificación de la mayoría de los frailejones con muy pocos falsos positivos). Por otro lado usando el ResNet-50 con fine-tuning parcial permitió alcanzar una precisión superior al 93%. Sin embargo, el mejor modelo fue el VGG16. Cabe aclarar que cada modelo podría estar dirigido hacia imágenes que cumplan con características específicas de acuerdo al rendimiento, por ejemplo, en una foto con alta iluminación el mejor modelo sería el convolucional, es por ello que una “combinación” de los modelos daría como resultado un mejor desempeño a la hora de identificar frailejones bajo diferentes características de la fauna.

## 8 REPORTE FINAL-CONCLUSIONES

---

En el contexto de los páramos como ecosistemas críticos para la regulación del agua, donde los frailejones juegan un papel fundamental en la captura y retención de agua, el estudio demostró que cuatro modelos de aprendizaje profundo lograron métricas bases sólidas en la identificación de estas especies vitales. El análisis detallado reveló las fortalezas particulares de cada modelo: el convolucional destacó en áreas de alta iluminación, las redes sencillas y multicapa en condiciones de iluminación intermedia, y el modelo VGG16 sobresalió en la diferenciación de frailejones de otras especies vegetales, con la menor tasa de falsos positivos.

El modelo VGG16 fue considerado el más efectivo debido a su rendimiento superior en métricas cuantitativas y cualitativas. Este hallazgo es particularmente relevante considerando que en áreas como el páramo de Chingaza, que abastece de agua a más del 70% de Bogotá, la precisión en la identificación de frailejones es muy importante para su conservación y monitoreo.

La capacidad de identificar frailejones con alta precisión es fundamental para el monitoreo y la conservación de los páramos, especialmente considerando su lento crecimiento de aproximadamente 1 cm por año y su vulnerabilidad ante amenazas como la expansión ganadera, incendios y cambio climático. Los frailejones son indicadores clave de la salud de estos ecosistemas, y su densidad poblacional refleja cambios ambientales críticos.

Estos modelos son especialmente valiosos para la investigación científica y la gestión de los páramos, facilitando estudios a gran escala sobre la distribución de frailejones y su respuesta al cambio climático. La capacidad de

diferenciar frailejones de otras plantas es crucial para la conservación, especialmente en contextos como los recientes incendios de enero 2024 en Chingaza y la crisis hídrica actual.

Los resultados del estudio también revelaron limitaciones en las técnicas tradicionales de procesamiento de imágenes. Por ejemplo, la conversión a escala de grises con umbral adaptativo genera falsos positivos, mientras que métodos avanzados como la estimación de densidad KDE han demostrado mayor precisión y generando mapas de calor de concentración poblacional.

Como sugerencia para futuros proyectos, considerando la crítica situación actual de los páramos y su importancia en el suministro de agua, se recomienda explorar la integración de diferentes modelos y técnicas, combinando el aprendizaje profundo con métodos de análisis espacial como KDE. Esta aproximación híbrida podría mejorar significativamente la precisión en la detección y caracterización de frailejones, contribuyendo a la conservación de estos ecosistemas vitales.

## 9 BIBLIOGRAFÍA

---

- **Rangel-Ch., J. O. (2000).** *Los páramos de Colombia: aspectos ambientales y socioeconómicos*. Instituto de Investigación de Recursos Biológicos Alexander von Humboldt.
- **Buytaert, W., Cuesta-Camacho, F., & Tobón, C. (2011).** "Potential impacts of climate change on the environmental services of humid tropical alpine regions." *Global Ecology and Biogeography*, 20(1), 19-33.
- **Hofstede, R., Segarra, P., & Mena Vásquez, P. (2003).** *Los páramos del mundo*. Global Peatland Initiative.
- **Instituto Humboldt & Parques Nacionales Naturales de Colombia (2017).** *Estado actual de los frailejones en Colombia*.
- **Van der Hammen, T., & Cleef, A. (1986).** "Development of the high Andean páramo flora and vegetation." *High Altitude Tropical Biogeography*, Oxford University Press.
- **IDEAM (2024).** *Informe sobre la sequía y niveles hídricos en Colombia debido al Fenómeno del Niño*. Instituto de Hidrología, Meteorología y Estudios Ambientales.
- **Parques Nacionales Naturales de Colombia (2024).** *Impacto de incendios forestales en el Páramo de Chingaza*.
- **LeCun, Y., Bengio, Y., & Hinton, G. (2015).** "Deep learning." *Nature*, 521(7553), 436-444.
- **Simonyan, K., & Zisserman, A. (2015).** "Very deep convolutional networks for large-scale image recognition." *arXiv preprint arXiv:1409.1556*. (Sobre VGG16)
- **Lecun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998).** "Gradient-based learning applied to document recognition." *Proceedings of the IEEE*, 86(11), 2278-2324.