

1 ENTENDIMIENTO DEL NEGOCIO

La industria del entretenimiento ha evolucionado drásticamente en los últimos años. Hace un par de décadas, para poder ver una película fuera del cine, era necesario comprarla o alquilarla en formato físico, ya fuera en videocasete o DVD, y contar con un dispositivo capaz de reproducirla. En esa época, modelos de negocio como Blockbuster o Betatonia ofrecían el alquiler de películas por unos pocos días, siempre en formato físico.

Con el surgimiento del internet y el avance acelerado en la velocidad de conexión, se ha transformado la manera en que consumimos contenido audiovisual. Hoy en día, es posible ver películas y series en línea, con alta calidad de imagen y sonido, sin necesidad de descargar previamente los archivos. Este modelo de consumo continuo es lo que conocemos actualmente como *streaming*. El auge del streaming desplazó a modelos tradicionales como el de Blockbuster, y dio paso a plataformas digitales como Netflix, Disney+, Max, Prime Video, entre otras. Estas plataformas permiten a los usuarios acceder a un catálogo amplio de películas, series y documentales bajo demanda, con reproducción instantánea, variedad de contenido, múltiples modelos de suscripción y compatibilidad con diversos dispositivos. El modelo de suscripción ha democratizado el acceso al contenido audiovisual, permitiendo disfrutarlo con tarifas mensuales, semestrales o anuales.

Sin embargo, a pesar de su éxito, este modelo de negocio enfrenta importantes retos. Uno de ellos es la capacidad de cada plataforma para ofrecer contenido original, relevante y personalizado, ajustado a los gustos individuales de cada usuario. En este contexto, mantener al usuario cautivado es clave para asegurar su permanencia y evitar la cancelación de la suscripción. Para ello, se vuelve indispensable contar con sistemas de recomendación inteligentes que identifiquen patrones de consumo y preferencias individuales.

La aplicación de algoritmos que permitan clasificar y recomendar contenido audiovisual genera ventajas clave para las plataformas: mejora la experiencia del usuario, optimiza el acceso al contenido y permite una segmentación más precisa del mercado. Una de las estrategias más efectivas para lograr esto es a través del análisis automático de las descripciones de las películas, las cuales contienen información valiosa que puede utilizarse para clasificarlas en géneros como Acción, Drama, Terror, Aventura, Animación, Infantil, Documental, entre otros. Esta clasificación no solo organiza el catálogo de forma más efectiva, sino que además es un insumo fundamental para construir motores de recomendación personalizados.

El problema de negocio identificado radica en el riesgo de que un usuario abandone su suscripción al no encontrar contenido relevante o sentirse abrumado por recomendaciones que no se ajustan a sus gustos. Además, desde una perspectiva técnica, aunque las descripciones de las películas contienen información rica en contenido semántico, el reto está en procesar ese texto de manera eficiente para extraer características relevantes y usarlas en la clasificación automatizada de géneros.

El objetivo principal del negocio es desarrollar un sistema automatizado de clasificación de películas por género, basado en el análisis de sus descripciones textuales, utilizando técnicas de procesamiento de lenguaje natural (PLN). Este sistema servirá como base para mejorar los motores de recomendación actuales y así aumentar la retención de usuarios en las plataformas de streaming.

2 OBJETIVOS DE MINERÍA DE DATOS

Como objetivo general del proyecto se plantea el desarrollo de un sistema automatizado de clasificación de películas por género, basado en el análisis de sus descripciones textuales, utilizando técnicas de procesamiento de lenguaje natural (PLN). Este sistema servirá como base para mejorar los motores de recomendación actuales y así aumentar la retención de usuarios en las plataformas de streaming.

Como objetivos de minería de datos para este proyecto se plantean:

- Preprocesar y analizar las descripciones de las películas para dejarlo en un formato adecuado para el análisis este procedimiento implica limpieza, normalización y tokenización de los datos de entrada.

- Extracción y valoración de las características o features de los textos usando técnicas como TF-IDF, Word embeddings, entre otras.
- Entrenar los modelos de clasificación supervisados para asignar uno o varios géneros por película a partir del análisis de las descripciones de las películas.
- Evaluar el desempeño de los modelos entrenados con la métrica de precisión AUC.
- Comparar las técnicas de extracción de características para identificar cuál produce mejores resultados.


3 ENTENDIMIENTO DE LOS DATOS

3.1 DESCRIPCIÓN DE LOS DATOS

Para el desarrollo de este proyecto se utilizaron datos con información de películas distribuidos en dos conjuntos: entrenamiento y prueba. El conjunto de entrenamiento contiene 7,895 registros con seis variables que incluyen: un identificador (int64), año (int64), título (object), trama (object), géneros (object) y rating (float64). Por su parte, el conjunto de prueba consta de 3,383 registros con cuatro variables, manteniendo solo el identificador, año, título y trama, excluyendo las variables de géneros y rating que serán objeto de predicción. Es importante resaltar que ambos conjuntos presentan datos completos, sin valores faltantes en ninguna de sus variables, lo que asegura la calidad de la información para el desarrollo del modelo.

Analizando las estadísticas de longitud de las tramas, observamos características similares entre ambos conjuntos:

En el Conjunto de Entrenamiento la longitud media de las tramas es de 748.82 caracteres, con una desviación estándar de 494.77. La trama más corta tiene 3 caracteres y la más larga 9,408. El 50% de las tramas tiene entre 412 (25%) y 951.50 (75%) caracteres, con una mediana de 655 caracteres. Y en el Conjunto de Prueba se presenta características similares, con una media de 749.44 caracteres y una desviación estándar de 486.16. La trama más corta tiene 8 caracteres y la más larga 3,863. El 50% de las tramas tiene entre 419 (25%) y 941 (75%) caracteres, con una mediana de 650 caracteres.




Los histogramas muestran que ambos conjuntos siguen una distribución similar, con una concentración de tramas entre 500 y 1000 caracteres, y una cola larga hacia la derecha, indicando algunas tramas significativamente más largas que el promedio.


3.2 EXPLORACIÓN DE LOS DATOS

Para comprender mejor la naturaleza y características de los datos, se realizó un análisis exploratorio que se centra en tres aspectos: distribución temporal, análisis de géneros y patrones de calificación, que permitirán identificar características relevantes para el desarrollo del modelo.

La distribución temporal de los datos abarca desde 1900 hasta 2020, donde se observa un crecimiento exponencial a partir de 1980. El período 2000-2020 concentra la mayor cantidad de películas, con más de 800 películas por año en el conjunto de entrenamiento y más de 300 en el de prueba. Esta distribución similar entre ambos conjuntos muestra una representatividad adecuada de la muestra de prueba, aunque indica un sesgo hacia el cine moderno.




La gráfica de la distribución de géneros muestra tres grupos claramente diferenciados. El primer grupo, conformado por Drama, Comedia, Thriller y Romance, domina la distribución con más de 1,500 películas cada uno, siendo Drama el género predominante. Un segundo grupo de géneros como Crime, Action, Adventure y Horror mantiene una presencia moderada. El tercer grupo, que incluye géneros como Documentary, Biography, War y géneros más especializados como Musical, Sport y News, tiene una representación significativamente menor. Esta estratificación en la distribución de géneros plantea desafíos importantes para el modelo, ya que deberá manejar eficazmente tanto géneros altamente representados como aquellos con muy pocos ejemplos de entrenamiento.



La gráfica de distribución de ratings muestra una distribución que se aproxima a una curva normal, con un sesgo hacia calificaciones positivas. La calificación promedio es de 6.40, con una desviación estándar de 1.07, lo que indica una variabilidad moderada en las opiniones. La mayoría de las películas se concentran en el rango de 6 a 7 estrellas, con el pico más alto alrededor de 6.5. Las calificaciones extremas (por debajo de 4 y por encima de 8) son relativamente poco comunes, lo que sugiere una tendencia central en la evaluación de películas. Esta distribución relativamente equilibrada de ratings facilitará el entrenamiento del modelo al proporcionar ejemplos representativos en diferentes niveles de calificación, aunque con un énfasis en el rango medio-alto.

3.3 REVISIÓN DE LA CALIDAD DE LOS DATOS

Para evaluar la calidad y características de los datos disponibles, se realizaron los siguientes análisis:



El gráfico de complejidad narrativa por género muestra patrones interesantes en la forma en que se escriben las tramas de diferentes géneros cinematográficos: En términos de longitud promedio, los géneros Drama, Film-Noir y Thriller muestran las tramas más extensas, lo que sugiere una tendencia hacia narrativas más desarrolladas y complejas. En contraste, géneros como Short, News y Animation tienden a tener tramas más concisas, lo cual es coherente con su naturaleza y formato.

En cuanto a la diversidad de vocabulario, es notable que la mayoría de los géneros mantienen un nivel similar de riqueza léxica (como se muestra en las barras verdes), lo que indica un estándar consistente en la variedad de lenguaje utilizado. Sin embargo, hay algunas excepciones notables, como News que muestra una diversidad de vocabulario significativamente menor, posiblemente debido a su enfoque más directo.



El análisis de las palabras más relevantes por género revela patrones lingüísticos distintivos y superposiciones que caracterizan a cada categoría cinematográfica. En Drama, Comedy y Romance predominan términos relacionados con relaciones personales y experiencias vitales ('life', 'love', 'family'), mientras que Thriller y Action se caracterizan por palabras que sugieren conflicto y tensión ('police', 'war'). Es destacable la presencia universal de elementos temporales ('time', 'new') y referencias a la individualidad ('man', 'young') en todos los géneros, aunque con diferentes connotaciones según el contexto: desde el desarrollo personal en Drama hasta la acción en Thriller. Esta superposición de vocabulario con distintos significados según el género representa un aspecto a considerar en el desarrollo del modelo ya que sugiere la necesidad de un análisis contextual más profundo que la simple identificación de palabras clave.

El mapa de calor de similitud entre géneros ofrece una visualización de las relaciones léxicas identificadas en el análisis anterior. Los valores más altos en la diagonal (Drama 0.03, Comedy 0.028, Thriller 0.029, Romance 0.031, Action 0.028) confirman que cada género mantiene un vocabulario distintivo. Sin embargo, se pueden ver las similitudes entre géneros: por ejemplo, la conexión entre Drama y Comedy (0.02) refleja el uso compartido de términos relacionados con la vida cotidiana y las relaciones personales que observamos en sus palabras más relevantes ('life', 'family', 'love'). Romance muestra la mayor distintividad en su vocabulario (0.031), lo que se evidencia en su uso único de términos específicos como 'woman' junto con 'love'. Esta matriz de similitud refuerza la necesidad de que el modelo considere no solo la presencia de ciertas palabras, sino también su contexto específico dentro de cada género.

3.4 DEL NUEVO CONJUNTO DE DATOS.

Para el nuevo conjunto de datos se aplicarán técnicas de preprocesamiento y transformación del texto que incluyen la eliminación de stopwords, caracteres especiales, espacios en blanco, así como la aplicación de lematización y stemming. El objetivo es obtener un conjunto de datos normalizado donde solo se mantengan las palabras más relevantes y significativas para el análisis. Los datos serán vectorizados utilizando dos enfoques principales: CountVectorizer y TfidfVectorizer, ambos configurados con parámetros específicos (max_features=1000, binary=True) para optimizar el rendimiento del modelo. Esta transformación permitirá convertir el texto en una representación numérica que los modelos de aprendizaje automático puedan procesar eficientemente.

Se espera que esta preparación de los datos mejore la calidad de la información de entrada para los modelos, facilitando la identificación de patrones y relaciones entre las tramas y los géneros cinematográficos.

4 METODOLOGÍA – PREPARACIÓN Y MODELAMIENTO

4.1 SELECCIÓN DE TÉCNICAS DE MODELADO.

En primer lugar, se realizan pruebas de diferentes métodos de preparación de la data con único modelo con el fin de elegir que metodologías emplear de la gran variedad que hay en preparación de data para modelos de lenguaje natural. Con las mejores estrategias de preparación de data se emplearán previas a modelos predictores de múltiples categorías como un XGBOOST Classifier o una regresión logística, aplicando búsqueda de hiperparámetros con optuna.

4.2 CONSTRUCCIÓN DEL MODELO IDENTIFICACIÓN AUTOMÁTICA DE FRAILEJONES

En primer lugar, se seleccionaron estrategias como bolsa de palabras, n-gramas, TF-IDF, tokenización, eliminación stopwords, eliminación de caracteres no alfanuméricos, stemming, lematización, vectorización y un modelo pre entrenado como spaCy.

La bolsa de palabras ofrece una representación textual sencilla al registrar la presencia de cada palabra en un documento, lo que la convierte en un buen punto de partida para análisis básicos. Los n-gramas extienden esta idea al considerar secuencias cortas de palabras, capturando así un contexto local que la bolsa de palabras ignora y mejorando la precisión en tareas sensibles al orden. Por otro lado, TF-IDF refina la representación al ponderar las palabras según su importancia dentro de un documento y su rareza en el conjunto de datos, destacando términos clave y reduciendo el ruido de palabras comunes.

La tokenización es un paso fundamental que descompone el texto en unidades manejables, permitiendo el conteo y el análisis individual de las palabras. La eliminación de stopwords complementa esto al descartar palabras de alta frecuencia, pero bajo contenido informativo, lo que enfoca el análisis en los términos más relevantes y reduce la dimensionalidad de los datos. Asimismo, la eliminación de caracteres no alfanuméricos asegura la limpieza y estandarización del texto, evitando interferencias de símbolos y puntuación en el procesamiento.

Las técnicas de stemming y lematización buscan normalizar las palabras, reduciéndolas a su forma raíz. El stemming lo hace de manera heurística, eliminando sufijos, mientras que la lematización utiliza el contexto y la gramática para obtener la forma base correcta, ofreciendo una normalización más precisa y lingüísticamente significativa. Finalmente, la vectorización transforma el texto procesado en representaciones numéricas, un formato esencial para alimentar la mayoría de los algoritmos de aprendizaje automático y permitir cálculos y comparaciones entre textos.

El uso de un modelo pre-entrenado como spaCy introduce una capa de sofisticación al aprovechar el conocimiento lingüístico adquirido previamente en grandes corpus de texto. Esto permite extraer características lingüísticas avanzadas como etiquetas gramaticales y entidades nombradas, así como obtener representaciones vectoriales de alta calidad para palabras y documentos. Esta transferencia de aprendizaje puede mejorar significativamente el rendimiento en diversas tareas de PNL, ofreciendo eficiencia y un profundo entendimiento del lenguaje desde el inicio.

A continuación, se presentan los resultados obtenidos en la preparación previa de la data

Bolsa de palabras	N-gramas y vectorización	TF-IDF	Tokenización, stopwords y filtración de no alfanuméricos	Lematización, Stemming	spaCy
0,770	0,750	0,751	0,769	0,789	0,794

Tal como se observa en la tabla anterior, las mejores estrategias para pre entrenar el modelo son lematización, stemming, stopwords y filtración de no alfanuméricos ya que son las que obtuvieron el mejor AUC aplicando un modelo básico de árboles.

A partir del procesamiento presentado con anterioridad se realizaron los siguientes modelos

PROYECTO #2 CLASIFICACIÓN DE GÉNEROS DE PELÍCULAS
TÓPICOS AVANZADOS DE ANALÍTICA

MARIA PAULA RAMOS - DAVID SANCHEZ - ANDRES SANTOS TOVAR - LEONARDO BECERRA



Modelo 1	Modelo 2	Modelo 3	Modelo 4	Modelo 5	Modelo 6
Pre procesamiento Data					
Stopwords	Stopwords	Stopwords	Stopwords	Stopwords	spaCy
Stemming	Stemming	Stemming	Stemming	Stemming	
Lematización	Lematización	Lematización	Lematización	Lematización	
filtración de no alfanuméricos	filtración de no alfanuméricos	filtración de no alfanuméricos	filtración de no alfanuméricos	filtración de no alfanuméricos	
Vectorización	Vectorización	Vectorización	TF-IDF	TF-IDF	
Modelo					
Xgboost Classifier	Regresión logística	Regresión logística	Regresión logística	Regresión logística	Regresión logística
Optuna Busqueda de hiperparámetros - subsample - Colsample_bytree - Max_depth - n_estimators - learning_rate - min_child_weight	n_jobs=-1 C=0,01 (inverso fuerza regularización multiclass=multinomial solver= "lbfgs" OneVsRestClassifier	Optuna Busqueda de hiperparámetros - inverso fuerza regularización - regularización - Solver OneVsRestClassifier	n_jobs=-1 C=0,01 (inverso fuerza regularización multiclass=multinomial solver= "lbfgs" OneVsRestClassifier	Optuna Busqueda de hiperparámetros - inverso fuerza regularización - regularización - Solver OneVsRestClassifier	Optuna Busqueda de hiperparámetros - inverso fuerza regularización - regularización - Solver OneVsRestClassifier
AUC test: 0,845	AUC test: 0,878	AUC test: 0,879	AUC test: 0,884	AUC test: 0,891	AUC test: 0,856

Dentro del modelamiento se emplearon algunas librerías y estrategias las cuales se presenta la explicación de porque fueron utilizadas.

Uso de Optuna para la Búsqueda de Hiperparámetros (Modelos 1, 3, 5 y 6)

- Optimización Automatizada: Optuna es una librería para la optimización automática de hiperparámetros. Su principal beneficio es que automatiza el proceso de encontrar la mejor combinación de hiperparámetros para un modelo dado. Esto ahorra tiempo y esfuerzo en comparación con la búsqueda manual o la experimentación aleatoria.
- Mejor Rendimiento del Modelo: Al explorar sistemáticamente diferentes configuraciones de hiperparámetros, Optuna tiene el potencial de encontrar combinaciones que resulten en un rendimiento significativamente mejor del modelo en comparación con los valores predeterminados o elecciones arbitrarias. Esto se ve reflejado en los resultados de AUC en los Modelos 3 y 5, que superan al Modelo 2 donde los hiperparámetros se definieron manualmente.
- Eficiencia en la Búsqueda: Optuna utiliza algoritmos de optimización (como Tree-structured Parzen Estimator - TPE) que son más inteligentes que la búsqueda de cuadrícula o la búsqueda aleatoria. Esto significa que explora el espacio de hiperparámetros de manera más eficiente, enfocándose en las regiones prometedoras y encontrando buenas soluciones en menos iteraciones.
- Reproducibilidad y Comparabilidad: Aunque el proceso de optimización en sí puede tener un componente aleatorio, al final se obtiene un conjunto específico de hiperparámetros que se pueden guardar y utilizar para reproducir los resultados. Esto facilita la comparación justa entre diferentes modelos o enfoques de preprocesamiento.

Selección y Ajuste Manual de Hiperparámetros Específicos (Modelo 2 y 4)

- Control y Comprensión: Definir manualmente hiperparámetros específicos permite un mayor control sobre el comportamiento del modelo y facilita la comprensión de cómo cada parámetro influye en el resultado. Por ejemplo, al fijar $C=0.01$ en la Regresión Logística, se está imponiendo una regularización específica con el objetivo de prevenir el sobreajuste.
- Conocimiento del Dominio: La selección manual de hiperparámetros puede basarse en el conocimiento experto del algoritmo y del problema específico. Por ejemplo, saber que un problema puede ser propenso al sobreajuste podría llevar a elegir un valor bajo para C en la Regresión Logística.
- Interpretación: Los valores de los hiperparámetros elegidos manualmente pueden ser más fáciles de interpretar en relación con el comportamiento del modelo (ej: una C pequeña implica una regularización fuerte).

- Exploración Dirigida: Si se tiene una buena intuición sobre qué rangos de hiperparámetros son importantes, la selección manual puede dirigir la exploración de manera más eficiente en esas áreas.

Uso de Diferentes Algoritmos de Modelado (Modelo 1 vs. Modelos 2-6)

- Exploración de la Idoneidad del Modelo: Utilizar diferentes algoritmos (XGBoost en el Modelo 1 y Regresión Logística en los demás) permite evaluar cuál modelo se adapta mejor a los datos y al problema. Cada algoritmo tiene sus propias fortalezas y debilidades en términos de cómo manejan las relaciones no lineales, la importancia de las características, la susceptibilidad al sobreajuste, etc.
- Potencial de Mejor Rendimiento: Un algoritmo puede ser inherentemente más adecuado para un tipo particular de datos o tarea, lo que puede resultar en un rendimiento superior en comparación con otros. En este caso, aunque XGBoost tuvo un buen rendimiento, la Regresión Logística con una buena optimización de hiperparámetros y preprocesamiento (Modelo 5) logró un AUC ligeramente mejor.

Estrategias de Clasificación Multiclase (OneVsRestClassifier)

- Adaptación a Problemas Multiclase: OneVsRestClassifier es una estrategia que permite utilizar algoritmos binarios (como la Regresión Logística) en problemas de clasificación con más de dos clases. Descompone el problema multiclase en múltiples problemas de clasificación binaria, donde se entrena un clasificador para cada clase versus todas las demás.
- Simplicidad y Amplia Aplicabilidad: Es una estrategia relativamente sencilla de implementar y funciona bien con muchos clasificadores binarios.

5 SOLUCIÓN PROPUESTA - EVALUACIÓN

El conjunto de modelos presentados explora diversas estrategias de preprocesamiento y algoritmos de clasificación para la tarea de predecir múltiples géneros a partir de descripciones de películas, con el objetivo de alcanzar un AUC de 0.89. El Modelo 1, utilizando XGBoost con un preprocesamiento básico y optimización de hiperparámetros con Optuna, obtuvo un AUC de 0.845, quedando por debajo de la meta. Los Modelos 2 y 3 emplearon la Regresión Logística con un preprocesamiento similar, diferenciándose en el ajuste de hiperparámetros (manual y con Optuna respectivamente), alcanzando AUCs de 0.878 y 0.879. Estos resultados sugieren que, si bien la optimización ayudó ligeramente, la capacidad lineal del modelo o la representación de los datos podrían ser limitantes.

Un avance significativo se observa en los Modelos 4 y 5, que incorporaron la técnica TF-IDF para ponderar la importancia de las palabras en las descripciones. El Modelo 4, con hiperparámetros de Regresión Logística ajustados manualmente, logró un AUC de 0.884, acercándose considerablemente a la meta. El Modelo 5, combinando el preprocesamiento con TF-IDF y la optimización de hiperparámetros con Optuna para la Regresión Logística, finalmente superó el objetivo con un AUC de 0.891. Este éxito subraya la importancia de una representación de texto que capture la relevancia de los términos para la predicción de género, así como el beneficio de una búsqueda exhaustiva de los mejores parámetros del modelo.

En contraste, el Modelo 6, que utilizó la librería de PNL spaCy para el preprocesamiento junto con la Regresión Logística optimizada con Optuna, obtuvo un AUC de 0.856, un rendimiento inferior al del Modelo 5. Esto indica que, para este problema específico, las técnicas de preprocesamiento más básicas combinadas con TF-IDF resultaron ser más efectivas que el enfoque de spaCy. En conclusión, el Modelo 5 demostró ser el más exitoso al alcanzar la meta de AUC, resaltando la efectividad de la representación TF-IDF y la optimización de hiperparámetros para la tarea de clasificación multietiqueta de géneros de películas.

6 REPORTE FINAL - CONCLUSIONES

El objetivo principal de este proyecto fue desarrollar un modelo de aprendizaje automático capaz de predecir los géneros a los que pertenece una película basándose únicamente en su descripción textual. La métrica clave para evaluar el rendimiento de los modelos fue el AUC, con una meta establecida de 0.89.

Se exploraron seis modelos distintos, variando en sus estrategias de preprocesamiento de datos y algoritmos de modelado

Los resultados mostraron una progresión en el rendimiento a medida que se refinaban las estrategias de preprocesamiento y se optimizaban los modelos. El Modelo 5, que combinó un preprocesamiento con TF-IDF y una Regresión Logística con hiperparámetros optimizados por Optuna fue el que logró alcanzar y superar la meta establecida, obteniendo un AUC de 0.891, cumpliendo con la meta establecida previamente. Este resultado superó a modelos que utilizaban un preprocesamiento más básico o una librería de PNL más compleja como spaCy.

En el contexto de la predicción de géneros de películas, un buen valor de AUC (cercano a 1) indica que el modelo tiene una alta capacidad para distinguir correctamente entre las películas que pertenecen a un género específico y aquellas que no, a través de diferentes umbrales de probabilidad. Un AUC de 0.89 significa que existe un 89% de probabilidad de que el modelo clasifique correctamente una película perteneciente a un género dado por encima de una película que no pertenece a ese género, cuando se eligen al azar ambas películas.

Dado que una película puede pertenecer a múltiples géneros (problema de clasificación multietiqueta), un buen AUC indica que el modelo es robusto en su capacidad para identificar la presencia o ausencia de cada género específico en función de la descripción.

La existencia de modelos con un buen AUC para la predicción de géneros a partir de descripciones tiene diversas repercusiones significativas para el contexto y la industria cinematográfica:

- Un modelo preciso puede enriquecer los sistemas de recomendación de películas. Al comprender mejor los géneros implícitos en la descripción, las plataformas de streaming y las bases de datos de películas pueden ofrecer sugerencias más relevantes y personalizadas a los usuarios, aumentando la satisfacción y el descubrimiento de contenido.
- La clasificación automática de géneros basada en la descripción puede agilizar y hacer más eficiente el proceso de catalogación y etiquetado de películas en grandes bases de datos. Esto reduce la necesidad de etiquetado manual exhaustivo y minimiza los errores humanos.
- los géneros que se infieren de la descripción pueden ayudar en la segmentación de audiencias para campañas de marketing más efectivas. Se pueden dirigir tráilers y promociones a los espectadores con mayor probabilidad de estar interesados en los géneros predichos.
- Un modelo robusto podría integrarse en herramientas para ayudar a los creadores de contenido a evaluar cómo se percibiría el género de su película basándose en la sinopsis inicial, permitiéndoles ajustar su enfoque si es necesario.

Para futuras mejoras del modelo, considerando la potencial complejidad no lineal inherente en la relación entre el lenguaje de las descripciones y la asignación de géneros, la exploración de otros modelos de aprendizaje automático se sugiere como una dirección prometedora. Modelos no lineales más avanzados, como Random Forest, Gradient Boosting Machines o incluso redes neuronales sencillas, podrían ser capaces de capturar patrones más intrincados en los datos, especialmente si se utiliza la representación TF-IDF que demostró su efectividad en los modelos lineales.

Adicionalmente, se podría investigar la implementación de técnicas de feature engineering más sofisticadas para extraer información aún más rica del texto. El uso de embeddings de palabras pre-entrenados, como Word2Vec, GloVe o FastText, podría proporcionar representaciones semánticas densas de las palabras, complementando o reemplazando la representación TF-IDF.

7 BIBLIOGRAFÍA

- **Statista.** (2024). *Global SVOD (Subscription Video On Demand) market revenue.* <https://www.statista.com/statistics/947384/global-svod-market-revenue/>
- **Business Insider.** (2025). *Why Netflix isn't worried if you cancel your subscription.* <https://www.businessinsider.com/netflix-chart-win-back-canceled-subscribers-2025-2>
- **Parks Associates.** (2024). *Annual churn rate for US streaming services reaches 47%.* <https://www.parksassociates.com/blogs/in-the-news/churn-rate-for-us-streamers-hits-47-percent>
- **Churnkey Blog.** (2024). *Churn Rates for Streaming Services.* <https://churnkey.co/blog/churn-rates-for-streaming-services>
- **Second Measure.** (2023). *Netflix vs. Disney+ vs. Apple TV+: Retention Trends.* <https://secondmeasure.com/datapoints/netflix-disney-plus-apple-customer-retention/>

- **PerfectRec.** (2023). *Chart: Streaming Service Churn Rates.*
<https://www.perfectrec.com/posts/chart-streaming-service-churn-rates>
- **Han, J., Kamber, M., & Pei, J. (2011).** *Data Mining: Concepts and Techniques (3rd ed.).* Elsevier. ISBN: 978-0123814791.
- **Feldman, R., & Sanger, J. (2006).** *The Text Mining Handbook: Advanced Approaches in Analyzing Unstructured Data.* Cambridge University Press. ISBN: 978-0521836579.
- **Manning, C. D., Raghavan, P., & Schütze, H. (2008).** *Introduction to Information Retrieval.* Cambridge University Press. ISBN: 978-0521865715.
<https://nlp.stanford.edu/IR-book/>
- **Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019).** *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.* In *Proceedings of NAACL-HLT.*
<https://arxiv.org/abs/1810.04805>
- **Scikit-learn Documentation – Text feature extraction using TF-IDF**
https://scikit-learn.org/stable/modules/feature_extraction.html#text-feature-extraction
- **Vaswani, A., et al. (2017).** *Attention Is All You Need.*
<https://arxiv.org/abs/1706.03762>
(Modelo base para los Transformers como BERT)
- **CRISP-DM Guide. (2000).** *CRISP-DM 1.0: Step-by-step data mining guide.*
<https://www.the-modeling-agency.com/crisp-dm.pdf>