

1. ENTENDIMIENTO DEL NEGOCIO

La base de datos PubMed indexa artículos científicos en el ámbito biomédico provenientes de diversas disciplinas como medicina, bioquímica, genética, farmacología y salud pública. Actualmente, esta base incluye más de 30 millones de referencias bibliográficas, lo que la convierte en una fuente clave para identificar tendencias de investigación y realizar análisis en el campo de la salud.

Desde una perspectiva estructural, la información contenida en PubMed puede modelarse como un grafo, donde los nodos representan entidades como artículos científicos, autores, revistas o términos MeSH (Medical Subject Headings), y los enlaces representan relaciones entre estos nodos. Estas relaciones pueden ser dirigidas o no dirigidas. Las relaciones dirigidas surgen, por ejemplo, cuando un artículo cita a otro, lo que sugiere una conexión temática entre ambos. Las relaciones no dirigidas pueden establecerse cuando dos artículos comparten el mismo autor, pertenecen a la misma revista o están etiquetados con los mismos términos MeSH.

El vocabulario MeSH es un tesoro controlado desarrollado por la Biblioteca Nacional de Medicina de los Estados Unidos (NLM), diseñado para clasificar, agrupar y jerarquizar artículos científicos dentro del área de la salud. Funciona como una estructura jerárquica en forma de árbol, compuesta por 16 categorías principales, que incluyen enfermedades, síntomas, diagnósticos, tratamientos, sustancias químicas, fármacos, entre otros. Cada término MeSH posee un identificador único y puede tener subcategorías que representan conceptos más específicos. Por ejemplo: Trastornos mentales → Trastornos de ansiedad → Trastorno de pánico.

El tesoro MeSH tiene múltiples aplicaciones en la investigación médica, entre las que se destacan:

- Integración con bases de datos clínicas, facilitando la interoperabilidad semántica.
- Recuperación y organización de literatura científica, mejorando la eficiencia de las búsquedas bibliográficas.
- Identificación de tendencias de investigación a través del análisis temporal de términos MeSH.
- Asociación de conceptos entre artículos, como por ejemplo, vincular tratamientos con enfermedades específicas.
- Clasificación automática de artículos científicos utilizando modelos de aprendizaje supervisado basados en las categorías MeSH.

El desarrollo de modelos predictivos basados en MeSH tiene importantes aplicaciones prácticas en el ámbito de la salud, entre ellas:

- Detección de efectos adversos asociados al uso de ciertos medicamentos mediante el análisis cruzado de términos MeSH en reportes clínicos.
- Identificación de patrones genéticos relacionados con la respuesta a tratamientos médicos.
- Monitoreo de brotes epidemiológicos, a partir del análisis de la frecuencia y distribución temporal de términos MeSH relacionados con síntomas o enfermedades.

En este contexto, el presente proyecto tiene como objetivo principal el desarrollo de modelos de aprendizaje automático sobre grafos (Graph Machine Learning), capaces de predecir las categorías MeSH correspondientes a artículos científicos nuevos. Estos modelos se basarán principalmente en la estructura de citaciones entre artículos y en sus relaciones semánticas, aprovechando la riqueza estructural y conceptual de la base de datos PubMed.

En esencia, se busca que el modelo pueda inferir el término MeSH principal que mejor describa el contenido temático de un artículo, entendiendo dicho término como una representación sintética y jerárquica del área de conocimiento al que pertenece la investigación.

2. OBJETIVOS DE MINERÍA DE DATOS

Los objetivos de minería de datos definidos para este proyecto están orientados al desarrollo de modelos predictivos basados en grafos, con el fin de etiquetar automáticamente artículos científicos con sus respectivas categorías *MeSH*. Estos objetivos se detallan a continuación:

- **Comprensión del grafo y los datos MeSH:** Analizar la estructura de la red de artículos de PubMed, identificando patrones topológicos relevantes (como nodos puente entre comunidades) y características clave de cada nodo para entender la distribución de las categorías MeSH.
- **Construcción del grafo con representaciones vectoriales:** Preparar los datos utilizando técnicas de embedding como Word2Vec, BERT y Node2Vec, para representar artículos y sus relaciones semánticas dentro del grafo.
- **Entrenamiento de modelos de aprendizaje automático sobre grafos:** Diseñar y entrenar modelos basados en grafos (como GCN, GraphSAGE, GAT) para predecir múltiples etiquetas MeSH por artículo, considerando su naturaleza multilabel.
- **Evaluación del desempeño del modelo:** Medir la precisión de los modelos utilizando métricas como accuracy y ROC-AUC, seleccionando aquellos con mejor capacidad de predicción y generalización. La **Accuracy** es útil por su simplicidad y porque indica directamente la proporción de predicciones correctas, dando una idea general de qué tan bien acierta el modelo. Por otro lado, el **AUC** es beneficioso porque evalúa la capacidad del modelo para **discriminar** entre las diferentes clases en un rango de umbrales, lo que es crucial en datasets donde la cantidad de ejemplos de una clase puede ser mucho mayor o menor que la de otra, proporcionando una medida más completa y robusta de la efectividad del modelo para distinguir los casos positivos de los negativos.

3. ENTENDIMIENTO DE LOS DATOS

3.1 DESCRIPCIÓN DE LOS DATOS



Ilustración 1. Gráficos de distribución de grados

El análisis descriptivo de la red PubMed revela una estructura dispersa y heterogénea. Con 19.717 nodos, 44324 conexiones y un grado promedio de 4, la mayoría de los nodos tienen pocas conexiones, aunque algunos alcanzan hasta 171, lo que sugiere la presencia de hubs altamente conectados. El grado promedio de los vecinos es considerablemente más alto (media de 19), lo que indica que nodos poco conectados tienden a relacionarse con nodos centrales. El coeficiente de clustering promedio es bajo (0,0601), con una mediana de 0, lo cual evidencia una escasa formación de triángulos y comunidades densas en la red. Estas características apuntan a una topología típica de redes reales, con una distribución sesgada del grado y una conectividad desigual, lo que representa un desafío para los modelos de aprendizaje profundo sobre grafos y refuerza la utilidad de enfoques como Node2Vec y GAT para capturar tanto relaciones estructurales como contextuales.

Distribución del Grado (izquierda): La mayoría de los nodos tienen un **grado bajo**, con una gran concentración en valores entre 1 y 5. Esta distribución está **altamente sesgada a la derecha**, lo que indica que existen pocos nodos con grados muy altos (hasta 171), conocidos como **hubs**. Esta es una característica típica de redes **scale-free**, donde unos pocos nodos concentran la mayoría de las conexiones.

Distribución del Grado Promedio de Vecinos (centro): Esta gráfica muestra que la mayoría de los nodos están conectados con vecinos que, en promedio, tienen un grado entre 10 y 30. Esto refuerza la idea de **conectividad desigual**, donde muchos nodos de grado bajo se relacionan con nodos más centrales. La cola larga hacia la derecha indica que algunos nodos se conectan con vecinos altamente conectados, lo cual puede ser clave para procesos de difusión o aprendizaje en grafos.

Distribución del Coeficiente de Clustering (derecha): Aquí se observa que la mayoría de los nodos tienen un **coeficiente de clustering cercano a 0**, es decir, sus vecinos no están conectados entre sí. Aunque existe un pequeño grupo con coeficientes cercanos a 1 (nodos altamente agrupados), la red en general tiene **baja cohesión local**. Esto sugiere una estructura más **arborescente** o **jerárquica** que modular, lo cual puede dificultar la detección de comunidades densas y representa un reto para tareas de clasificación basadas en vecindad.




Ilustración 2. Matriz de correlación de características topológicas.




Ilustración 3. Matriz de correlación de métricas de centralidad.

La **matriz de correlación** de la ilustración 2 entre las características topológicas de los nodos revela relaciones débiles entre las variables consideradas. En primer lugar, la correlación entre el **grado** de un nodo y el **grado promedio de sus vecinos** es **ligeramente negativa** (-0.0988), lo cual sugiere que los nodos altamente conectados tienden, en promedio, a estar rodeados de nodos menos conectados, lo que es típico en redes disasortativas como muchas redes reales. Por otro lado, la correlación entre el **grado** y el **coeficiente de clustering** es **ligeramente positiva** (0.0369), lo cual indica que tener más conexiones no implica necesariamente una mayor o menor cohesión local, aunque la relación es prácticamente despreciable. Finalmente, la relación entre el **grado promedio de vecinos** y el **coeficiente de clustering** también es débilmente positiva (0.0330). En resumen, las **bajas correlaciones** indican que estas métricas aportan información complementaria y no redundante sobre la estructura del grafo, lo cual es útil para modelos que intentan aprender representaciones ricas y variadas de los nodos.




Ilustración 4. Métricas de centralidad

El análisis de centralidad aplicado a los **nodos** de una red con 19,717 elementos muestra una estructura dispersa. En cuanto a la **degree centrality** (centralidad de grado), se observa que la mayoría de los nodos tienen una conectividad directa muy baja, con una mediana de apenas 0.000101, lo que indica que pocos nodos actúan como hubs en la red. Respecto a la **betweenness centrality** (centralidad de intermediación), los valores son cercanos a cero para la mayoría de los nodos, lo que sugiere que estos no son rutas críticas dentro de la red, aunque existe un nodo con un valor máximo de 0.1428 que probablemente actúe como un puente clave entre grupos desconectados. En términos de **closeness centrality** (centralidad de cercanía), los valores presentan poca dispersión, con una media de 0.160 y un máximo de 0.249, lo que indica que la red mantiene una eficiencia moderada en cuanto a la distancia promedio entre nodos. Finalmente, la **eigenvector centrality** muestra que la mayoría de los nodos tienen baja influencia global (mediana de 1.22e-05), aunque algunos alcanzan valores elevados (máximo de 0.1719), lo que sugiere que hay nodos muy influyentes conectados a otros también influyentes. En conjunto, los resultados evidencian una red en la que unos pocos nodos estratégicos sostienen la conectividad, influencia y flujo de información.

La **matriz de correlación entre métricas de centralidad** de la ilustración 3, revela relaciones importantes en la estructura de la red. La **degree centrality** muestra una correlación moderadamente alta con la **betweenness centrality** (0.597), lo cual indica que los nodos con más conexiones directas suelen desempeñar también un papel como intermediarios entre otros nodos. Además, la **degree centrality** está moderadamente correlacionada tanto con la **closeness centrality** (0.510) como con la **eigenvector centrality** (0.507), lo que sugiere que los nodos bien conectados tienden a estar más cerca del resto y a conectarse con nodos influyentes. En contraste, la **betweenness centrality** tiene una correlación baja con la **closeness centrality** (0.274) y aún más baja con la **eigenvector centrality** (0.100), lo que indica que actuar como puente en la red no está necesariamente relacionado con tener influencia o estar cerca de todos los nodos. Finalmente, la **closeness centrality** y la **eigenvector centrality** presentan una correlación baja (0.211), lo que sugiere que la cercanía promedio a todos los nodos no implica alta relevancia estructural en

términos de conexiones influyentes. Estas relaciones reflejan que cada métrica captura un aspecto distinto de la centralidad en la red.

3.2. EXPLORACIÓN DE LOS DATOS

El gráfico de Pareto muestra una red altamente asimétrica, donde la gran mayoría de los nodos tienen muy pocas conexiones (grados bajos), mientras que un pequeño porcentaje son "hubs" con numerosas conexiones. Esta distribución, típica de redes complejas, significa que aproximadamente el 80% de los nodos tienen un grado muy bajo. Esta heterogeneidad estructural es clave, y el modelo de clasificación se beneficia al integrar información como los embeddings de Node2Vec y la adyacencia directa, que capturan eficazmente la importancia tanto de los nodos de bajo grado como de los más importantes.




Ilustración 5. Pareto entre nodos y conexiones

Ahora, tenemos como features los resúmenes de cada artículo bajo un vector tf-idf cada uno. Las características de los nodos, extraídas como vectores TF-IDF de los resúmenes de los artículos, demuestran ser altamente distintivas para cada clase, con cada categoría exhibiendo un conjunto único de términos clave de alto peso que facilitan su discriminación. El análisis de similitud de coseno confirma la eficacia de TF-IDF para identificar relaciones semánticas: aunque la mayoría de los documentos muestran baja similitud entre sí, existen pares con una afinidad temática extremadamente alta, incluso identidades casi perfectas, lo que sugiere duplicados o artículos muy relacionados. Adicionalmente, el examen de los términos TF-IDF con mayor peso a nivel de toda la colección subraya los conceptos globales más relevantes y frecuentes en el dominio. Esta rica información textual, al complementar los datos estructurales del grafo (como Node2Vec y la adyacencia), ha sido un pilar fundamental para el sobresaliente rendimiento del modelo de clasificación combinado.




Ilustración 6. Clustering categorías




Ilustración 7. Distribución frecuencia por términos.

La ilustración 6 muestra que **K-Means logra formar clusters visualmente distinguibles** a partir de las características TF-IDF proyectadas en 2D. Esto indica que los datos textuales tienen una **estructura inherente de agrupamiento**, lo que valida su utilidad para complementar la información del grafo y contribuir al rendimiento del modelo combinado. Por último, la ilustración 7 muestra que la **mayoría de los términos aparecen en un porcentaje bajo de documentos** (menos del 10%), lo que indica que el vocabulario está compuesto en gran parte por palabras muy específicas o poco comunes, cruciales para la diferenciación individual de los documentos. A medida que aumenta el porcentaje de documentos en los que aparece un término, el número de dichos términos disminuye drásticamente, lo cual es una distribución esperada en colecciones de texto y **beneficia directamente al TF-IDF**, permitiéndole asignar mayor importancia a los términos discriminativos y de menor frecuencia.

4. PREPARACIÓN DE LOS DATOS

Durante el proceso de preparación de los datos, se trabajó directamente con las features entregadas de los resúmenes de cada documento médico, las cuales ya incluían representaciones vectorizadas mediante técnicas TF-IDF. Dado que estos vectores estaban previamente procesados, no fue necesario realizar un preprocesamiento textual adicional. Se consideró inicialmente la posibilidad de aplicar una reducción de dimensionalidad, con el fin de mejorar la interpretabilidad del modelo y reducir el riesgo de sobreajuste. Sin embargo, tras evaluar el rendimiento de los modelos en las primeras iteraciones, se observó un buen desempeño sin necesidad de dicha reducción. Por esta razón, se optó por conservar los vectores TF-IDF como features centrales en la fase de modelado. En cuanto a los datos estructurados como grafo, se analizó la cantidad de nodos y conexiones. Se identificó que cada nodo mantenía al menos dos conexiones, lo cual garantizaba una conectividad básica dentro del grafo. Además, se evidenció un comportamiento tipo Pareto: aproximadamente el 20% de los nodos concentraban el 80% de las conexiones. Esta característica estructural se mantuvo sin modificaciones, al representar adecuadamente la dinámica y distribución de las relaciones en la red. En conjunto, estas decisiones

permitieron trabajar con una representación de datos robusta, sin necesidad de transformaciones adicionales, lo que facilitó el enfoque hacia el diseño y evaluación de modelos de aprendizaje automático.

5. METODOLOGÍA - MODELAMIENTO

5.1. Selección de técnicas de modelado.

Para la construcción del modelo de clasificación de tipos de documentos médicos, la selección de las técnicas de modelado se basó en la naturaleza del problema, las características de los datos y los requerimientos de precisión y eficiencia del sistema. Dado que se trataba de una tarea de clasificación supervisada, se consideraron algoritmos robustos como árboles de decisión, redes neuronales, regresión logística y xgboost. Adicionalmente, se evaluaron modelos basados en el aprovechamiento de las conexiones del grafo para hacer embeddings de los nodos usando modelos como el Node2Vecs, especialmente útiles para capturar la relación entre documentos médicos. La elección final se realizó comparando el rendimiento de cada modelo en términos de métricas como el AUC y la precisión, priorizando aquellos que ofrecieran un buen rendimiento predictivo.

5.2. Construcción del modelo clasificación de documentos médicos

5.2.1 Modelo base.

Para tener una línea base sobre la cual entrenar los modelos de grafos se plantea un entrenamiento de modelos base con los features básicos con modelos tradicionales sin incluir las estructuras de los grafos. Se entrenan principalmente modelos de clasificación como regresión logística, random forest, XGBoost y un último modelo usando features estructurales sin usar GNNs. Los resultados de los entrenamientos de estos modelos y sus correspondientes configuraciones se detallan a continuación:

Regresión Logística	RandomForest	XGBoost-1	XGBoost-2	XGBoost-3	Features Estructurales
Max_iter=1000	n_estimators=100 m_state=42	n_estimators=100 learning_rate=0.1 max_depth=3	learning_rate=0.1, max_depth=3, n_estimators=200, subsample=0.8, colsample_bytree=0.8, reg_alpha=0.1, reg_lambda=0.1, random_state=42, tree_method='gpu_hist'	Mismos hiperparámetros que el anterior pero con balanceo de clases.	
F1-Score=0.7303 Accuracy = 0.7290 AUC=0.8575	F1-Score=0.7563 Accuracy = 0.7390 AUC=0.8575	F1-Score=0.7128 Accuracy = 0.7080 AUC=0.8575	F1-Score=0.7111 Accuracy=0.7000 AUC=0.8575	F1-Score=0.7111 Accuracy=0.7000 AUC=0.8691	F1-Score=0.5279 Accuracy=0.5390 AUC=0.8575

5.2.2 Modelo Node2Vec

Con el objetivo de obtener representaciones vectoriales (embeddings) de los nodos presentes en el grafo médico PubMed, se utilizó el modelo Node2Vec, una técnica de aprendizaje no supervisado que genera vectores para cada nodo a partir de caminatas aleatorias en el grafo. Este enfoque es útil para capturar relaciones estructurales y semánticas entre entidades (por ejemplo, artículos científicos relacionados por citas). Se definió un espacio de búsqueda de hiperparámetros para explorar distintas configuraciones del modelo. Entre los parámetros evaluados se incluyeron: la dimensión del embedding, la longitud y el número de caminatas aleatorias por nodo, el tamaño del contexto para el entrenamiento, los parámetros de retorno y exploración del grafo (p y q), y el número de muestras negativas utilizadas en el proceso de entrenamiento.

Los mejores hiperparámetros encontrados para Node2Vec fueron: vectores de 64 dimensiones, caminatas de 20 pasos, tamaño de contexto 5, 10 caminatas por nodo, con $p = 0.5$ y $q = 2.0$, y 20 muestras negativas. Tener una dimensionalidad de 64 implica que cada documento es representado con un vector moderadamente detallado, lo que permite capturar relaciones relevantes sin generar una representación demasiado compleja. El hecho de que p sea menor que q favorece la exploración del grafo, permitiendo que las caminatas le den prioridad a una búsqueda local antes que una búsqueda global. Esta configuración equilibrada mejoró la calidad de los embeddings para su uso en tareas de clasificación de documentos médicos. Teniendo en cuenta los embeddings construidos con anterioridad, se realizaron los siguientes modelos.

Modelo Node2Vec con regresión logística	Modelo Node2Vec con random forest	Modelo Node2Vec con xgboost	Modelo Node2Vec con red neuronal
- One-vs-Rest (ovr), lo que significa que el modelo entrena un clasificador binario por cada clase, distinguiéndola del resto.	- Búsqueda de hiperparámetros - Gridsearch - Mejor combinación: 'class_weight': 'balanced', 'max_depth': None,	- Búsqueda de hiperparámetros - Gridsearch - Mejor combinación: 'colsample_bytree': 0.8,	- Búsqueda de hiperparámetros - Gridsearch - Mejor combinación: 'hidden_dim': 64, 'learning_rate': 0.001,

- Embeddings de Node2Vec como variables predictorias (entradas) y las etiquetas reales de los documentos como salida - Función de pérdida: Log-Loss (pérdida logística multiclase)	'min_samples_leaf': 3, 'min_samples_split': 2, 'n_estimators': 200, 'random_state': 42 - Embeddings de Node2Vec como variables predictorias (entradas) y las etiquetas reales de los documentos como salida - Función de pérdida: Log-Loss (pérdida logística multiclase) - Optimizador Adam	'learning_rate': 0.1, 'max_depth': 7, 'n_estimators': 200, 'num_class': 3, 'objective': 'multi:softmax', 'random_state': 42, 'subsample': 0.8 - Embeddings de Node2Vec como variables predictorias (entradas) y las etiquetas reales de los documentos como salida - Función de pérdida: Log-Loss (pérdida logística multiclase) - Optimizador Adam	'dropout_rate': 0.2, 'num_layers': 3, 'epochs': 50 - Embeddings de Node2Vec como variables predictorias (entradas) y las etiquetas reales de los documentos como salida - Función de pérdida: Log-Loss (pérdida logística multiclase) - Optimizador Adam
AUC train:0.9205 AUC test:0.9216 Acc Train:0.794 Acc Test: 0.803	AUC train:0.9991 AUC test:0.9394 Acc Train:0.978 Acc Test: 0.827	AUC train:1.00 AUC test:0.940 Acc Train:0.998 Acc Test: 0.834	AUC train:0.974 AUC test:0.942 Acc Train:0.887 Acc Test: 0.828

En el caso del modelo de regresión logística, los resultados muestran una excelente generalización: la diferencia entre el AUC en entrenamiento y prueba es prácticamente inexistente (0.9205 vs 0.9216), y en accuracy incluso mejora ligeramente en el conjunto de prueba (0.794 vs 0.803). Esto indica que el modelo no está sobreajustado, pero también sugiere que puede estar subajustado, es decir, que no está capturando toda la complejidad de los datos, lo que se refleja en sus métricas más bajas frente a otros modelos.

Por otro lado, el modelo de Random Forest presenta una clara señal de sobreajuste. Tiene un rendimiento casi perfecto en entrenamiento (AUC de 0.9991 y accuracy de 0.978), pero estas métricas caen de forma notable en el conjunto de prueba (AUC de 0.9394 y accuracy de 0.827). Esta diferencia indica que el modelo se adaptó muy bien a los datos de entrenamiento, pero pierde capacidad de generalización, lo que lo hace menos robusto para nuevos datos, aunque sigue siendo competitivo.

El modelo de XGBoost, aunque tiene el mejor rendimiento en prueba (AUC de 0.940 y accuracy de 0.834), muestra un comportamiento similar al de Random Forest en cuanto al sobreajuste. Su rendimiento en entrenamiento es perfecto (AUC de 1.0 y accuracy de 0.998), pero las diferencias con respecto al conjunto de prueba son amplias. Esto evidencia un sobreajuste más marcado. A pesar de ello, es el modelo que logra mejor desempeño general, por lo que podría afinarse con técnicas de regularización para mejorar su generalización.

Finalmente, el modelo de red neuronal logra un equilibrio bastante adecuado. Aunque su rendimiento en entrenamiento (AUC de 0.974 y accuracy de 0.877) es superior al de prueba (AUC de 0.942 y accuracy de 0.828), las diferencias son moderadas. Esto sugiere una buena capacidad de generalización, posiblemente lograda por técnicas como el dropout y un adecuado ajuste de hiperparámetros. Este modelo ofrece un buen compromiso entre rendimiento y robustez.

Cabe aclarar que en cada modelo se observaron valores de pérdida inferiores a 0.1. Tener valores de **función de pérdida muy cercanos a cero** durante el entrenamiento de un modelo indica, en principio, que el modelo está aprendiendo de manera efectiva y ajustando sus predicciones muy cerca de los valores reales en el conjunto de datos de entrenamiento. Esto es una señal positiva de que el algoritmo de optimización está funcionando y que el modelo está encontrando un buen ajuste para esos datos. Sin embargo, una pérdida de entrenamiento extremadamente baja debe considerarse con precaución, ya que puede ser un fuerte indicio de **sobreajuste (overfitting)** lo cual ocurre en los últimos modelos.

5.2.3. Modelo Node2Vec con matriz de adyacencia

Para este modelo se toman los mismos embeddings de los modelos anteriores ya que con búsqueda de hiperparámetros garantiza una estructura correcta que representa el grafo y se emplea también la matriz de adyacencia. Por un lado, los *embeddings* obtenidos mediante **Node2Vec**, y por otro, la **matriz de adyacencia** del grafo, modificada para incluir la diagonal (es decir, que cada nodo se considera vecino de sí mismo). Esta integración se hace con el propósito de capturar tanto las características latentes que reflejan similitudes estructurales de los nodos como la estructura explícita de conectividad del grafo. A continuación, se presenta la descripción de cada uno.

Modelo Node2Vec + matriz de adyacencia con red neuronal 1	Modelo Node2Vec + matriz de adyacencia con red neuronal 2
- Capa lineal y ReLU - Capa <i>dropout</i> , con el fin de reducir el riesgo de sobreajuste - Optimizador Adam - Función de pérdida de entropía cruzada - Entrenando el modelo en mini-lotes - Embeddings de Node2Vec como variables predictorias (entradas) junto con la matriz de adyacencia y las etiquetas reales de los documentos como salida - Regularización L2	- Búsqueda de hiperparámetros - Gridsearch - Mejor combinación: 'hidden_dim': 256, 'learning_rate': 0.01, 'dropout_rate': 0.7, 'weight_decay': 0.0001, 'epochs': 50 - Embeddings de Node2Vec como variables predictorias (entradas) junto con la matriz de adyacencia y las etiquetas reales de los documentos como salida - Función de pérdida: Log-Loss (pérdida logística multiclase) - Optimizador Adam - Regularización L2
AUC train:1.00 AUC test:0.916 Acc Train:0.999 Acc Test: 0.810	AUC train:0.997 AUC test:0.937 Acc Train:0.974 Acc Test: 0.826

El Modelo 1 fue entrenado sin una optimización explícita de hiperparámetros. Este modelo alcanzó métricas casi perfectas en el conjunto de entrenamiento, con un AUC de 1.00 y una precisión de 0.999. Sin embargo, en el conjunto de prueba, estas métricas disminuyen significativamente: el AUC cae a 0.916 y la precisión a 0.810. Esta diferencia indica claramente la presencia de overfitting, es decir, el modelo aprendió muy bien los datos de entrenamiento, pero su capacidad de generalización es limitada.

Por su parte, el Modelo 2 fue ajustado mediante una búsqueda de hiperparámetros usando GridSearch. Gracias a este proceso, el modelo logró un mejor equilibrio entre desempeño en entrenamiento y prueba. Aunque sus métricas en entrenamiento son ligeramente más bajas que las del Modelo 1 (AUC de 0.997 y precisión de 0.974), presenta una mejor capacidad de generalización, alcanzando un AUC de 0.937 y una precisión de 0.826 en el conjunto de prueba.

los nuevos modelos que combinan embeddings de Node2Vec con la matriz de adyacencia superan en rendimiento a todos los modelos anteriores, incluyendo a XGBoost. La diferencia más significativa se observa en la **mejora de la capacidad de generalización**. Esto valida la hipótesis de que incluir tanto la representación vectorial de los nodos como su contexto estructural (adyacencia) permite capturar información más rica, mejorando así las predicciones.

5.2.4 Modelo red neuronal convolucional

Este modelo implementa una red neuronal en PyTorch que combina tres tipos distintos de información sobre nodos en un grafo para realizar clasificación: embeddings de Node2Vec, características originales de los nodos, y filas de la matriz de adyacencia.

La red neuronal propuesta, TripleInputModel, contiene tres subredes lineales independientes que procesan cada tipo de entrada por separado. Sus salidas se concatenan y pasan por una capa final que realiza la clasificación. La arquitectura incluye ReLU como función de activación y Dropout para evitar el sobreajuste. Posteriormente, se define un procedimiento sistemático para evaluar múltiples combinaciones de hiperparámetros (dimensión oculta, tasa de aprendizaje, dropout, regularización L2, y número de épocas) utilizando una búsqueda manual sobre una grilla definida. El modelo se entrena para cada configuración usando el conjunto de entrenamiento y se evalúa en el conjunto de validación. Los resultados del modelo se presentan a continuación.

Modelo Node2Vec + matriz de adyacencia+features con red neuronal convolucional
- Búsqueda de hiperparámetros - Gridsearch - Mejor combinación: {'hidden_dim': 64, 'learning_rate': 0.05, 'dropout_rate': 0.5, 'weight_decay': 1e-05, 'epochs': 100} - Embeddings de Node2Vec como variables predictoras (entradas) junto con la matriz de adyacencia y features, al igual que las etiquetas reales de los documentos como salida - Función de pérdida: Log-Loss (pérdida logística multiclase-Cross entropy) - Optimizador Adam - Regularización L2
AUC train: 0.996 AUC test: 0.971 Acc Train: 0.959 Acc Test: 0.891

El modelo muestra un desempeño excelente en entrenamiento y validación. Un AUC de 0.996 en entrenamiento y 0.971 en test indica que el modelo tiene una gran capacidad para discriminar entre las diferentes clases de documentos, y que esta capacidad se mantiene al aplicarlo a datos nuevos, lo cual es un buen indicador de generalización. La precisión (accuracy) también es alta, con 95.9% en entrenamiento y 89.1% en test, y aunque hay una caída entre ambos, esta es razonable y esperada en problemas multicategoría reales, donde siempre hay cierta complejidad y ruido en la clasificación.

Desde la perspectiva del overfitting, los resultados sugieren que no hay un sobreajuste problemático. La diferencia pequeña en AUC entre train y test y la presencia de dropout y weight decay para regularización apuntan a que el modelo está aprendiendo patrones generales y no simplemente memorizando los datos de entrenamiento. Sin embargo, la caída un poco más significativa en accuracy podría indicar que ciertas clases menos frecuentes o documentos con características más ambiguas están generando errores en la predicción, lo cual es común en datos de publicaciones científicas con diversidad en tipos documentales.

Bajo el contexto de datos de PubMed, donde la clasificación de tipos de documentos puede incluir categorías muy disímiles (artículos originales, revisiones, editoriales, cartas, etc.), este modelo robusto y bien regularizado es una gran ventaja. Permite capturar la compleja relación estructural entre documentos —por ejemplo, citas o temas relacionados— y usarla junto con características textuales para mejorar la precisión de clasificación. Esto es especialmente importante porque clasificar manualmente grandes bases de datos bibliográficos es costoso y propenso a errores, y un modelo con este nivel de rendimiento puede ayudar a automatizar procesos de curación, búsqueda y análisis bibliométrico con buena confianza.

5.2.5 Modelo usando grados del nodo

Modelo 1

Un modelo de clasificación de nodos en un grafo utilizando únicamente el grado de cada nodo (es decir, el número de conexiones que tiene) como característica principal. Aunque es un enfoque simple, permite establecer una línea base para comparar con modelos más complejos en tareas de clasificación en grafos.

Dentro del primer modelo se implementa un preprocesamiento de datos cálculo y normalización de grados. El grado de un nodo es el número de conexiones que tiene con otros nodos en el grafo. Este valor se calcula y se normaliza para que tenga una media de 0

y una desviación estándar de 1, lo que ayuda a que el modelo aprenda de manera más estable. La normalización es importante porque evita que valores muy grandes o muy pequeños afecten negativamente el entrenamiento.

La arquitectura del modelo y de entrenamiento del modelo se realizaron de la siguiente manera:

El modelo es una red neuronal simple con dos capas lineales:

1. Capa de entrada (1D $\rightarrow$ 16D): Transforma el grado del nodo en un vector de 16 dimensiones.
2. Capa de salida (16D $\rightarrow$ Número de clases): Clasifica el nodo en una de las categorías disponibles.

Para evitar el sobreajuste, se aplica Dropout (con una probabilidad del 50%) durante el entrenamiento, lo que ayuda a que el modelo generalice mejor.

Durante el entrenamiento se siguió el flujo típico en aprendizaje automático:

1. Paso Forward: El modelo predice las clases de los nodos.
2. Cálculo de Pérdida: Se usa la función Negative Log-Likelihood Loss (NLL Loss) para medir el error.
3. Paso Backward: Se ajustan los pesos del modelo mediante descenso de gradiente.
4. Optimización: Se utiliza el optimizador Adam con una tasa de aprendizaje de 0.01 y regularización L2 (weight decay).

Los resultados muestran que el modelo basado únicamente en el grado de los nodos alcanza solo un 31% de precisión, lo que confirma que esta característica estructural no es suficiente para clasificar efectivamente los nodos en el grafo de PubMed. El análisis detallado revela un desempeño desigual: mientras que la Clase 2 tiene un recall aceptable (62%), la Clase 1 no se logra predecir (0% F1-score), probablemente debido a desbalanceo de datos o falta de correlación entre el grado y las categorías. Estas limitaciones implican que, aunque el grado nodal ofrece cierta información (evidente en la Clase 2), se requieren características adicionales (como atributos textuales o métricas de centralidad) y modelos más sofisticados (como GNNs) para capturar relaciones complejas en el grafo. Este experimento, no obstante, establece una línea base valiosa: demuestra que incluso características simples pueden tener algo de poder predictivo, pero también subraya la necesidad de incorporar contextos más ricos para lograr clasificaciones robustas.

Modelo 2- MLP con características estructurales avanzadas

Este segundo modelo representa una evolución significativa respecto al enfoque inicial basado únicamente en grados nodales. La principal innovación radica en la incorporación de tres métricas:

1. Grado nodal (número de conexiones directas),
2. Grado promedio de vecinos (captura información local sobre la conectividad circundante),
3. Coeficiente de clustering (mide la tendencia a formar comunidades cerradas).

La arquitectura implementada es un MLP de dos capas con dropout (50%) para regularización, que procesa estas características concatenadas. Durante el entrenamiento (100 épocas con Adam y weight decay), el modelo mostró una mejora sustancial frente al baseline inicial.

El segundo modelo, que incorpora grado nodal, grado promedio de vecinos y coeficiente de clustering, muestra una ligera mejora frente al modelo basado únicamente en grados (31.4% vs 31.0% de exactitud). Sin embargo, el análisis detallado revela cambios significativos en el comportamiento del modelo:

- Mejora en la Clase 0:
 1. El recall aumentó del 34% al 57%, indicando que el modelo ahora detecta mejor esta clase.
 2. La precisión bajó (de 17% a 21%), sugiriendo que hay más falsos positivos.
- Problemas persistentes en la Clase 1:
 1. Aunque la precisión mejoró (de 0% a 43%), el recall se mantuvo bajo (25%), lo que indica que el modelo aún ignora muchos casos reales de esta clase.
- Clase 2:
 1. El rendimiento empeoró (F1-score de 49% a 32%), mostrando que las nuevas características introdujeron ruido en esta categoría.
- Conclusiones clave:
 1. Las métricas estructurales adicionales no son suficientes para capturar las relaciones complejas en el grafo.
 2. El modelo sigue sesgado hacia la Clase 0 (alto recall) pero penaliza a la Clase 2.
 3. La Clase 1, aunque mejoró, requiere estrategias específicas (ej.: oversampling).

5.2.6. Modelo usando atención

Modelo 1

Dentro del modelo se implementa una arquitectura híbrida para la clasificación de nodos en grafos. En una primera etapa, se generan **embeddings de nodos** con el algoritmo **Node2Vec**, el cual simula recorridos aleatorios sobre el grafo para capturar relaciones estructurales y de contexto. Los vectores resultantes son usados como representación inicial para cada nodo. Posteriormente, se entrena un modelo **Graph Attention Network (GAT)** sobre estos embeddings. Este modelo aplica mecanismos de atención para ponderar la importancia de los vecinos en el grafo durante el proceso de agregación de información, mejorando la capacidad de aprendizaje contextual. Durante el entrenamiento, se evalúa el desempeño en los conjuntos de validación y prueba, utilizando métricas como **exactitud**, **reporte de clasificación** y **matriz de confusión** para interpretar los resultados. La combinación de Node2Vec y GAT permite una representación rica y jerárquica de los nodos, aprovechando tanto la estructura del grafo como los patrones locales de conectividad para mejorar la clasificación.

Los resultados del modelo híbrido Node2Vec + GAT sobre el conjunto de prueba muestran un desempeño sólido en la clasificación de nodos del grafo **PubMed**, alcanzando una **exactitud general del 73,6%**. El **reporte de clasificación** revela un equilibrio razonable entre precisión y recall en las tres clases evaluadas. En particular, la clase **1**, que representa la mayor proporción del conjunto de prueba (413 ejemplos), obtuvo el mejor rendimiento con una **precisión de 0,72**, **recall de 0,80** y un **F1-score de 0,76**, indicando una capacidad robusta del modelo para identificar correctamente estas instancias. La clase **2** también mostró un F1-score competitivo (0,74), aunque con un ligero desequilibrio entre precisión (0,81) y recall (0,69). La clase **0** fue la más desafiante para el modelo, con métricas más bajas pero aún aceptables (F1-score de 0,67). El **macro promedio (0,72)** y el **promedio ponderado (0,74)** del F1-score sugieren que el modelo mantiene un buen rendimiento general, incluso con clases desbalanceadas. Estos resultados validan el enfoque combinado de aprendizaje de representaciones estructurales mediante Node2Vec y clasificación basada en atención con GAT, lo que demuestra ser una estrategia efectiva para tareas de clasificación en grafos complejos.

Modelo 2

En este segundo enfoque, se mejoró la arquitectura mediante dos componentes principales: una mayor profundidad en la generación de *embeddings* con **Node2Vec** y una red **GAT con múltiples heads, Batch Normalization y Dropout**. Los embeddings fueron generados con parámetros más robustos (`walk_length=20`, `context_size=10`, `walks_per_node=20`), lo que permite capturar una representación estructural más rica del grafo. Adicionalmente, se utilizó un entrenamiento más extenso (50 épocas), lo que mejora la estabilidad del espacio vectorial. Por el lado del modelo GAT, se introdujo una capa adicional de regularización con **BatchNorm** y **LeakyReLU**, así como **Dropout del 60%** para reducir el sobreajuste. La capa GAT inicial utiliza **4 cabezas de atención** concatenadas, permitiendo capturar múltiples patrones de relaciones entre nodos. Esto se complementa con una segunda capa GAT que proyecta hacia el espacio de salida sin concatenación. Este diseño busca explotar de manera más eficiente la atención sobre nodos en el grafo, aprendiendo de representaciones más densas y regulares. Se observó una mejor generalización en validación y prueba, lo cual sugiere una mejor capacidad del modelo para adaptarse a nuevas estructuras nodales. La exactitud y el reporte de clasificación mostraron una mejora respecto al primer modelo, evidenciando que las técnicas de regularización y el aumento de la complejidad de la arquitectura contribuyen positivamente al rendimiento.

El modelo GAT con Node2Vec ha demostrado un rendimiento excepcional, logrando un 72.4% de exactitud en el conjunto de prueba, lo que representa una mejora de más del doble respecto a los enfoques anteriores basados en características estructurales manuales. El análisis detallado revela un equilibrio notable entre precisión (71-79% por clase) y recall (66-80%), superando especialmente el problema crítico de la Clase 1 que los modelos previos no podían clasificar (F1-score de 0.76 vs 0 originalmente). Estos resultados validan que la combinación de embeddings estructurales aprendidos (Node2Vec) + mecanismos de atención gráfica (GAT) captura patrones complejos que las aproximaciones tradicionales pasaban por alto, estableciendo un nuevo paradigma para el análisis de grafos científicos donde el aprendizaje automático de representaciones supera significativamente a las características manuales. La consistencia en las métricas (F1 promedio de 0.71) sugiere que el modelo generaliza bien across todas las clases, aunque oportunidades de mejora persisten, particularmente en la Clase 0 (F1=0.64), donde estrategias como el aumento de cabezas de atención o la incorporación de características semánticas podrían llevar el rendimiento por encima del 75%.

6. Solución propuesta - Evaluación

La evaluación de los diversos modelos construidos reveló una clara progresión en la capacidad de clasificación. Las aproximaciones iniciales, basadas únicamente en características estructurales simples como el grado del nodo, arrojaron una precisión extremadamente baja (alrededor del 31%), demostrando la insuficiencia de estas características aisladas para un problema tan complejo. Los modelos que utilizaron solo los *embeddings* de Node2Vec, aunque significativamente mejores, mostraron un techo de rendimiento (máximo de 83.4% de *Accuracy* en prueba con XGBoost) y a menudo exhibieron un sobreajuste considerable. La adición de la matriz de adyacencia a los *embeddings* de Node2Vec en modelos de red neuronal logró una mejora en la generalización, validando la importancia de incluir la conectividad explícita del grafo. Finalmente, los modelos que incorporaron atención de grafo (GAT con Node2Vec) representaron un salto cualitativo significativo, superando los modelos anteriores con una exactitud del 73.6% al 72.4% y demostrando una capacidad notable para manejar clases difíciles, como la Clase 1.

De todos los enfoques explorados, el **Modelo Combinado Final (Node2Vec + Matriz de Adyacencia + Features TF-IDF con Red Neuronal Convolutiva, o TripleInputModel)** se destacó como el **claro ganador**. Con una **precisión del 89.1%** y un **AUC**

de 0.971 en el conjunto de prueba, este modelo supera consistentemente a todos los demás. Su superioridad radica en la **integración sinérgica de tres fuentes de información complementarias**: los *embeddings* de Node2Vec capturan la estructura latente del grafo, la matriz de adyacencia aporta la conectividad explícita entre documentos, y las características TF-IDF introducen el valioso contenido semántico textual. La arquitectura de red neuronal, junto con una rigurosa optimización de hiperparámetros y técnicas de regularización, fue capaz de aprender las relaciones complejas y no lineales entre estas diversas fuentes de datos, lo que le permite alcanzar una capacidad de discriminación y precisión sin precedentes.

Las implicaciones de este modelo de alto rendimiento para la Biblioteca de Estados Unidos de Medicina son transformadoras. Con una precisión cercana al 90%, el modelo permite una **automatización masiva y altamente fiable de la categorización de documentos médicos**. Esto no solo aumentará drásticamente la **eficiencia operativa** al liberar recursos humanos y reducir errores en el proceso de curación de datos, sino que también mejorará la **recuperación de información** para millones de investigadores y profesionales de la salud, quienes podrán encontrar de manera más rápida y precisa la literatura relevante. Además, garantiza una **consistencia en la categorización** que sería inalcanzable manualmente, sentando las bases para análisis bibliométricos más fiables y el desarrollo de nuevos servicios de valor añadido, validando la superioridad de un enfoque híbrido que combina estructura del grafo y contenido textual.

7. Reporte final-conclusiones

Durante este proyecto se trabajó en el desarrollo de un sistema de clasificación de documentos médicos para PubMed de PyTorch, abordando un crucial problema multicategoría para la Biblioteca Nacional de Medicina de Estados Unidos. Para evaluar la efectividad de nuestros modelos, nos centramos en la **Precisión (Accuracy)**, que mide la tasa de aciertos directos, fundamental para la usabilidad y organización diaria de la base de datos, y el **Área bajo la Curva ROC (AUC)**, especialmente relevante en contextos multicategoría al evaluar la capacidad discriminativa del modelo para distinguir cada clase del resto. El AUC es vital para asegurar la fiabilidad de las predicciones, incluso ante desequilibrios de clases, garantizando que el sistema pueda diferenciar con alta confianza entre categorías médicas diversas.

Nuestro viaje de modelado evolucionó desde aproximaciones simples hasta complejas soluciones híbridas. Iniciamos con modelos basados en características estructurales básicas como el grado nodal, que revelaron ser insuficientes con apenas un 31% de precisión. Progresamos a modelos que incorporaban *embeddings* de Node2Vec, que capturan la estructura latente del grafo, mejorando significativamente el rendimiento, aunque con desafíos de sobreajuste. La inclusión posterior de la matriz de adyacencia a los *embeddings* de Node2Vec en modelos de redes neuronales, y la exploración de redes de atención de grafos (GAT), marcaron hitos importantes al validar la capacidad de estas características estructurales para enriquecer las representaciones de los nodos y mejorar la generalización, elevando la precisión a rangos del 72-73%.

Sin embargo, el **Modelo Combinado Final (Node2Vec + Matriz de Adyacencia + Features TF-IDF con Red Neuronal Convolutiva)** se erigió como el **claro ganador indiscutible**. Este modelo alcanzó una **precisión del 89.1% y un AUC de 0.971 en el conjunto de prueba**, superando drásticamente a todos los demás. Su éxito radica en la **sinergia excepcional de tres fuentes de información complementarias**: los *embeddings* de Node2Vec que capturan la complejidad estructural de la red de citas, la matriz de adyacencia que proporciona la conectividad explícita entre documentos, y las características TF-IDF que incorporan el contenido semántico y temático explícito de los resúmenes. La robusta arquitectura de red neuronal, junto con una meticulosa optimización de hiperparámetros y técnicas de regularización, permitió al modelo aprender las relaciones complejas y no lineales inherentes a esta rica combinación de datos.

Las **implicaciones para el negocio de la Biblioteca Nacional de Medicina de Estados Unidos son profundas y transformadoras**. Una precisión cercana al 90% en la clasificación automatizada de documentos médicos representa un salto cualitativo gigantesco. Primero, generará una **eficiencia operacional sin precedentes**, al automatizar una tarea manual que es costosa, lenta y propensa a errores, liberando a los especialistas para tareas de curación de contenido más complejas. Segundo, y quizás lo más importante, **revolucionará la recuperación de información**: los investigadores, médicos y el público en general encontrarán la literatura médica pertinente de forma más rápida, precisa y fiable, lo cual es crítico en un campo donde la información oportuna puede salvar vidas. Tercero, asegura una **consistencia y uniformidad en la categorización** que no es posible con métodos manuales, mejorando la calidad y fiabilidad de toda la base de datos de PubMed. Finalmente, este modelo abre la puerta a **capacidades analíticas avanzadas**, como la detección de tendencias emergentes en la investigación o la identificación de vacíos en el conocimiento, solidificando la posición de PubMed como un recurso indispensable y de vanguardia para la comunidad médica global.

Bibliografía

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. arXiv preprint arXiv:1912.01703. <https://arxiv.org/abs/1912.01703>
En este trabajo se utilizó el conjunto de datos **PubMed** del benchmark **Planetoid**, cargado a través de la biblioteca **PyTorch Geometric** para tareas de clasificación de nodos en grafos.

```
@article{paszke2019pytorch,  
  title={PyTorch: An Imperative Style, High-Performance Deep Learning Library},  
  author={Paszke, Adam and Gross, Sam and Massa, Francisco and Lerer, Adam and Bradbury, James and Chanan,  
Gregory and Killeen, Trevor and Lin, Zeming and Gimelshein, Natalia and Antiga, Luca and others},  
  journal={arXiv preprint arXiv:1912.01703},  
  year={2019},  
  note={Dataset PubMed del benchmark Planetoid fue utilizado mediante PyTorch Geometric para clasificación de  
nodos en grafos}  
}
```

Fey, M., & Lenssen, J. E. (2019). *Fast Graph Representation Learning with PyTorch Geometric*. arXiv preprint arXiv:1903.02428. https://pytorch-geometric.readthedocs.io/en/latest/generated/torch_geometric.datasets.Planetoid.html

U.S. National Library of Medicine. (n.d.). *About the National Library of Medicine*. National Institutes of Health. <https://www.nlm.nih.gov/>

National Center for Biotechnology Information. (n.d.). *PubMed*. U.S. National Library of Medicine. <https://pubmed.ncbi.nlm.nih.gov/>